
CosyVoice 3: 通过规模扩展和后训练实现野外环境下的语音生成

Zhihao Du, Changfeng Gao, Yuxuan Wang, Fan Yu, Tianyu Zhao, Hao Wang, Xiang Lv, Hui Wang, Chongjia Ni, Xian Shi, Keyu An, Guanrou Yang, Yabin Li, Yanni Chen, Zhifu Gao, Qian Chen, Yue Gu, Mengzhe Chen, Yafeng Chen, Shiliang Zhang, Wen Wang, Jieping Ye

Speech Team, Tongyi Lab, Alibaba Group

{ neo.dzh, funaudiollm } @alibaba-inc.com

Abstract


在我们之前的工作中，我们介绍了一种可扩展的流式语音合成模型 CosyVoice 2，该模型集成了大型语言模型 (LLM) 和分块感知流匹配 (FM) 模型，实现了低延迟双向流式语音合成和媲美真人语音的质量。尽管取得了这些进展，CosyVoice 2 在语言覆盖范围、领域多样性、数据量、文本格式和后训练技术方面仍然存在局限性。在本文中，我们提出了 CosyVoice 3，这是一种改进的模型，专为野外零样本多语言语音合成而设计，在内容一致性、说话人相似性和韵律自然度方面均超越了其前身。CosyVoice 3 的关键特性包括：1) 一种新的语音分词器，用于提高韵律自然度，该分词器通过监督式多任务训练开发，包括自动语音识别、语音情感识别、语言识别、音频事件检测和说话人分析。2) 一种新的可微分奖励模型，适用于后训练，不仅适用于 CosyVoice 3，也适用于其他基于 LLM 的语音合成模型。3) 数据集规模扩展：训练数据从一万小时扩展到一百万小时，涵盖 9 种语言和 18 种汉语方言，涉及各种领域和文本格式。4) 模型规模扩展：模型参数从 0.5 亿增加到 1.5 亿，由于更大的模型容量，在我们的多语言基准测试中性能得到了提升。这些进展极大地推动了野外语音合成技术的发展。我们鼓励读者访问 <https://funaudiollm.github.io/cosyvoice3> 试听演示。

1 引言


随着生成式神经网络的快速发展，文本到语音 (TTS) 合成技术取得了显著进展，在合成质量方面超越了传统的拼接式和参数式方法 [1–7]。特别是，零样本 TTS 模型利用庞大的多说话人数据集，可以克隆任何说话人的音色、韵律和风格，并展现出优于特定说话人 TTS 模型的性能，实现了接近人类的韵律自然度和音频质量 [8]。

目前，零样本文本转语音 (TTS) 模型大致可分为三类：使用大型语言模型 (LLM) 对离散声学标记进行建模的模型 [8–17]；基于扩散模型自动学习语音和文本之间内部对齐的模型 [18–26]；以及使用自回归 LLM 对粗粒度语义进行建模，然后使用非自回归模型（例如扩散模型）渲染详细语音特征的粗粒度到细粒度混合系统 [26–32]。考虑到合成质量、流式传输兼容性和灵活性之间的权衡，这种两阶段混合系统已成为工业应用中的主流选择。在我们之前的工作中，我们开发了 CosyVoice 2 [30]。通过优化语义标记利用率、使用基于文本的 LLM 进行初始化、设计双向流式传输方案以及统一指令能力建模，CosyVoice 2 实现了与人类语音媲美的合成质量，以及几乎无损的超低延迟双向流式传输合成能力 [30]。

尽管 CosyVoice 2 在一般的中文和英文广播场景中表现良好，但在语言覆盖范围、领域多样性、数据量和文本格式多样性方面存在明显的局限性，在实现真实场景下的语音生成方面仍有很大的改进空间。此外，模型和数据的缩放定律以及适用于语音生成模型的后训练技



(a) Content Consistency



(b) Speaker Similarity

Figure 1: 我们的 CosyVoice 3 与其他竞争性语音生成模型在各种基准测试中内容一致性和说话人相似性方面的性能比较。图 (a) 中的内容一致性数字是 ASR 模型测量的 CER 或 WER。图 (b) 中的说话人相似性数字是参考语音和生成语音之间 WavLM 嵌入的余弦相似度。错误率 100.00 和相似度 0.00 表示发布的模型不支持这些语言。

术尚未得到彻底探索。为了解决这些问题，我们推出了 CosyVoice 3，这是一款专为真实场景应用而设计的大型零样本语音生成模型，涵盖更多语言和多样化场景，并在内容一致性、说话人相似性和韵律自然度方面显著超越了其前身 CosyVoice 2。我们的贡献可总结如下：通过这些改进，CosyVoice 3 在多个基准测试中取得了最先进 (SOTA) 的成果。我们相信 CosyVoice 3 代表着向实际应用场景下的语音合成迈出了坚实的一步。

2 CosyVoice 3




Figure 2: 图示 (a) 监督式多任务训练的语音分词器和 (b) CosyVoice 3 的训练流程。虚线框中的模块仅在训练阶段使用。语音分词器在 ASR、语言识别 (LID)、语音情感识别 (SER)、音频事件检测 (AED) 和说话人分析 (SA) 任务上进行监督训练。CFM 表示条件流匹配模型。

图 2 展示了监督式多任务语音分词器和 CosyVoice 3 生成模型的训练过程。与之前的 CosyVoice 2 不同，CosyVoice 3 中的语音分词器基于 MinMo [33]，这是一个预训练的大规模语音理解模型，在各种语音任务上都表现出色 [33]。我们还概述了零样本模型和说话人微调 (SFT) 模型的训练流程，包括大规模预训练、后训练、持续预训练和多说话人微调。后训练阶段旨在克服训练数据的性能限制，而持续预训练阶段则专注于将零样本模型的能力（例如指令控制能力和多语言合成能力）迁移到 SFT 模型。

如图 2 a 所示，与 CosyVoice 2 将有限标量量化 (FSQ) 模块 [34] 插入到 SenseVoice-Large ASR 模型 [35] 的编码器中不同，对于 CosyVoice 3，我们将 FSQ 模块插入到 MinMo 模型 [33] 的语音编码器中。与 SenseVoice-Large ASR 模型相比，MinMo 是一种先进的多模态大型语言模型，在超过 140 万小时的语音数据集上进行训练，并在各种基准测试中展现出卓越的性能，包括语音对话、多语言语音识别和情感识别。为了进一步增强捕获语义信息的能力，我们利用 MinMo 训练数据的一个子集（约 53 万小时）对我们的语音分词器进行监督式多任务学习，包括多语言 ASR、语言识别 (LID)、语音情感识别 (SER)、音频事件检测 (AED) 和说话人分析 (SA) 等任务。

在训练阶段，输入语音 X 经过图 2 a 中的 Voice Encoder₁ 获得中间表示 H ，其中 Voice Encoder₁ 由 12 个带有旋转位置嵌入 (RoPE) [36] 的 Transformer 块组成。然后将中间表示 H 输入到 FSQ 模块进行量化，量化后的表示通过 MinMo 的其余模块（包括 Voice Encoder₂ 和 MinMo LLM）来预测相应文本标记的后验概率。

在 FSQ 模块中，中间表示 H 首先被投影到 D 维低秩空间，并且每个维度的值使用有界舍入操作 ROUND 量化为 $[-K, K]$ 。然后，量化后的低秩表示 $\bar{H}$ 被投影回原始维度 $\hat{H}$ ，如下所示：

$$\begin{aligned}\bar{H} &= \text{ROUND}(\text{Proj}_{\text{down}}(H)) \\ \hat{H} &= \text{Proj}_{\text{up}}(\bar{H})\end{aligned}\tag{1}$$

在训练阶段，使用直通估计来近似 FSQ 模块和 Voice Encoder₁ 的梯度。语音 token μ_i 是通过计算量化低秩表示 $\bar{h}_i$ 在 $(2K+1)$ 进制系统中的索引获得的：

$$\mu_i = \sum_{j=0}^{D-1} \bar{h}_{i,j} (2K+1)^j\tag{2}$$

Voice Encoder₁、FSQ 模块的低秩投影器、有界舍入操作和索引计算共同构成了 CosyVoice 3 的语音分词器。我们的语音分词器以 25 Hz 的速率工作，即每秒生成 25 个语音 token。

2.1 基于可微分奖励优化的强化学习

最近的 TTS 系统 [26, 37] 表明，强化学习 (RL) 在提高生成语音质量方面是有效的。然而，据我们所知，尚未建立一种适用于语音生成的通用强化学习方法。与自然语言处理任务中的大型语言模型不同，TTS 系统需要额外的下游条件流匹配 (CFM) 和声码器模型将离散的语音 token 转换为音频波形。这些下游模型对计算资源的需求很大。更严重的是，经过下游处理后，生成的语音始终表现出高度相似性；因此，很难区分用于训练奖励模型的正反馈和负反馈。

为了解决这些问题，我们引入了可微分奖励优化 (DiffRO) 方法，直接优化语音 token 而不是合成音频。DiffRO 首先在 ASR 训练数据上训练一个类似 ASR 的 Token2Text 模型，然后使用后验概率作为奖励。为了进一步简化训练策略，DiffRO 使用 Gumbel-Softmax 操作对 LLM 预测的 token 进行采样，然后直接优化语音 token，并通过反向传播最大化奖励分数，而不是使用强化学习训练循环：

$$\tilde{\mu}_t = \text{GumbelSoftmax}_{P_{\pi_\theta}}(\mu_t | \mu_{1:t-1}; Y) \quad (3)$$

$$R_{ASR}(Y) = \log P_{ASR}(\tilde{Y}_n = Y_n | Y_{1:n-1}; \tilde{\mu}_{1:T}) \quad (4)$$

其中 μ_t 和 $\tilde{\mu}_t$ 分别表示真实语音 token 及其在时间步长 t 处的采样预测。 R_{ASR} 是基于类似 ASR 的 Token2Text 模型计算的奖励函数。由于 $R_{ASR}(Y)$ 的目标是鼓励 $\tilde{\mu}$ 捕获文本中的所有信息，因此它可以帮助 TTS 系统清晰准确地理解文本。因此，我们可以直接优化 LLM，使其输出 token 与 ASR 偏好对齐，并使用 Kullback-Leibler (KL) 散度来防止模型偏离参考模型太远。与其他强化学习方法不同，我们在输出 token 级别的 logits 上计算 KL 散度，而不是在序列级别的后验概率上计算。

$$\pi_\theta^* = \max_{\pi_\theta} \mathbb{E}[R(Y)] - \beta D_{KL}[\pi_\theta(\mu|Y) \| \pi_{\text{ref}}(\mu|Y)] \quad (5)$$

$$D_{KL}[\pi_\theta(\mu|Y) \| \pi_{\text{ref}}(\mu|Y)] = \sum_{t=1}^T \sum_{k=0}^Q P_{\pi_\theta}(\mu_t = k) \log \left(\frac{P_{\pi_\theta}(\mu_t = k)}{P_{\pi_{\text{ref}}}(\mu_t = k)} \right) \quad (6)$$

其中 Q 是 FSQ 模块的码本大小，等于 $(2K+1)^{D-1}$ 。

除了 Token2Text 模型之外，DiffRO 还使用其他下游任务，例如 SER、MOS 分数预测、AED 和其他音频理解任务进行多任务奖励 (MTR) 建模。MTR 机制可以帮助 TTS 系统根据指令控制语音属性 $\{A_i\}_{i=1}^K$ 。

$$R_{MTR}(Y, \{A_i\}_{i=1}^K) = \sum_i \log P_{\text{task}_i}(\tilde{A}_i = A_i | \tilde{\mu}) \quad (7)$$

基于 LLM 的 TTS 系统主要使用 BPE 文本分词器，以原始文本作为输入。与传统的基于音素的方法相比，这些系统在发音控制方面缺乏可控性。具体来说，当遇到由多音字或训练数据中稀疏或未出现的罕见词引起的错误发音时，缺乏基于人工干预的鲁棒方法。

为了构建一个在发音方面可有效控制的工业级文本转语音 (TTS) 系统，我们将 CosyVoice 3 扩展，使其能够对单词和音素的混合序列进行建模，并扩展了分词器的词汇表。为了实现这一目标，我们构建了一个辅助训练集，方法是使用拼音替换中文单音字，并使用 CMU 发音词典将英文单词替换为音素。该辅助数据集被添加到基础训练集中。

在文本分词之前，TTS 系统通常会通过文本规范化 (TN) 模块处理原始文本，将数字和特殊符号转换为其对应的文本表达形式，但这依赖于大量人工编写的规则；然而，这些人工规则在处理特殊符号的覆盖范围方面不断面临挑战。

我们探索使用大型语言模型 (LLM) 执行文本规范化 (TN) 任务，从而构建更加统一的端到端文本转语音 (TTS) 系统。我们以原始文本作为输入，采用三种方法构建辅助训练集：1) 我们将原始文本输入内部基于规则的 TN 模块，获得规范化文本，并使用 CosyVoice 2 合成音频。2) 我们提示 Qwen-Max [38] 进行文本规范化，然后使用 CosyVoice 2 对规范化文本合成音频。3) 我们提示 Qwen-Max 对现有文本-音频对中的文本进行逆向文本规范化，获得原始文本（即未规范化文本）。我们将原始文本及其对应的音频视为配对样本，并直接添加到基础训练集中。我们验证了在新扩展训练集上训练的新系统可以直接合成原始文本，并且在各种特殊符号上表现出更好的鲁棒性和覆盖范围。

指令式语音生成

指令式语音生成 为了增强 CosyVoice 3 的可控性和表现力，与 CosyVoice 2 相比，我们将更多富有表现力的语音数据集成到基础训练集中。高质量指令遵循数据的时长从 1500 小时扩展到 5000 小时，涵盖更广泛的类型，包括情感、语速、语调、方言、口音和角色扮演。总类型数量增加到 100 多种，如表 2.1 所示。与 CosyVoice 2 类似，CosyVoice 3 也支持语言指令和细粒度指令。对于自然语言指令，语音合成的输入文本前会添加自然语言描述和一个特殊的结束标记 “<| endofprompt |>”。对于细粒度指令，支持文本标记之间的语音爆发和语音特征标签进行控制。例如，输入文本中的 “[laughter]” 和 “[breath]” 等标记可分别用于生成明显的笑声和呼吸声。标签 “XXX ” 用于强调特定单词。

adventurous	ambitious	ancient	angry
artistic	authoritative	bold	brave
calm	charming	cheerful	clever
commanding	compassionate	confident	conflicted
contempt	courageous	creative	cunning
curious	dark	deceptive	dedicated
defiant	determined	disciplined	disgusted
empathetic	energetic	fearful	fearless
happy	heroic	hopeful	humble
imaginative	indifferent	insightful	intelligent
introspective	joyful	loyal	merciless
mysterious	noble	objective	optimistic
passionate	patient	proud	relaxed
relentless	responsible	sad	selfless
serious	shocked	stealthy	surprised
vengeful	vigilant	wise	fast
loud	slow	soft	adventurer
alchemist	architect	chef	craftsman
detective	doctor	girl	knight
leader	merchant	peppa	poet
robot	ruler	scholar	wanderer
warrior	witch	youth	anhui dialect
cantonese dialect	chongqing dialect	hebei dialect	shandong dialect
shanghai dialect	sichuan dialect	tianjin dialect	xi'an dialect
zhengzhou dialect	chinese english accent	indian english accent	russian english accent

预训练数据中出现频率最高的 100 种说话风格。

预训练数据中出现频率最高的 100 种说话风格。

Table 1: 预训练数据中出现频率最高的 100 种说话风格。

说话者微调中的能力迁移

说话者微调中的能力迁移

2.1.1 将单语说话者转变为多语说话者

CosyVoice 3 相较于其前身的一个显著改进是扩展了语言支持。为了使单语目标说话者能够说多种语言，我们构建了一个辅助训练数据集，其中包含从随机选择的说话者那里收集的涵盖所有支持语言的录音室质量的单语数据。每个话语的说话者 ID 和语言 ID 都通过自然语言指令指定。

2.1.2 指令生成能力的迁移

使用特定说话者数据对预训练模型进行微调可以提高单个说话者生成输出的质量和表现力。我们开发了一个部分标注了说话者 ID 的训练数据集。它包含目标说话者的高质量数据以及预训练的指令遵循数据集。在自然语言指令提示中，我们指定说话者提示和风格提示。例如，完整的指令提示可能是 “你是说话者 A。请开心地和我说话。” 但是，某些数据条目可

Examples

- UTF8gsn 你是说话人小明。请讲法语。
 - You are Speaker B. Please speak German.
-

Table 2: 多语言 SFT 数据集中自然语言指令的示例。

能缺少说话者 ID 或风格标签；在这种情况下，我们在提示中将这些字段留空。在在微调过程中，我们还会随机遮蔽说话人提示或风格提示，以增强模型的迁移能力。这种方法确保了对不同说话人的指令进行全面覆盖，并有助于防止预训练模型在指令生成过程中出现灾难性遗忘。

与中文和英文相比，获取其他语言的大规模高质量文本转语音（TTS）数据更具挑战性。为了应对这一挑战，我们主要从互联网有声书、视频和播客中收集真实世界的多语言音频数据。然后，我们实施了一个多语言数据处理流程，以生成足够高质量的模型训练数据。该流程包括以下六个步骤：1. 语音检测和分割；2. 降噪；3. 自动语音识别（ASR）转录；4. 标点符号调整；5. 音量标准化；6. 过滤掉音频文本长度比异常的数据。

原始数据由说话人分割、语音活动检测（VAD）和音频事件检测模块依次处理。最终得到时长小于 30 秒的说话人级别的语音片段。虽然我们在这一过程中使用内部开发的模块，但也可以使用开源替代方案来实现相同效果。

我们使用 MossFormer2 模型进行降噪。接下来，根据语音片段开头和结尾帧的能量水平，筛选出由于异常截断而导致开头或结尾包含不完整单词的语音片段；剩余的语音片段，去除开头和结尾的静音部分后，保留用于进一步处理。

为了获得足够可靠的文本转录，我们首先使用 Faster-Whisper Large-V3 进行语言识别，然后使用不同的开源自动语音识别（ASR）模型（Faster-Whisper Large-V3、NVIDIA NeMo Canary-1B、Meta FAIR seamlessM4T-V2-large）对语音片段进行转录。然后，我们进行交叉验证，并从不同系统的 ASR 结果中选择平均成对词错误率（WER）低于 15% 的转录结果。

由于 ASR 生成的文本中的标点符号可能无法正确反映相应音频中的实际停顿，我们使用 Montreal Forced Aligner 来计算单词、子句或短语之间的持续时间，然后根据预设阈值添加或删除标点符号（300 毫秒添加逗号，50 毫秒删除表示停顿的标点符号，例如逗号、分号、冒号、句号、问号和感叹号）。

音量标准化。 应用简单直接的归一化方法进行音量标准化：

$$\text{normalized_wav} = \frac{\text{raw_wav}}{\max(\text{raw_wav})} \times 0.6 \quad (8)$$

过滤掉音频-文本长度比率异常的语音。 完成上述所有处理步骤后，提取每个生成的语音-文本对的语音标记和文本标记。然后，计算并排序每个语音-文本对的语音标记和文本标记的长度比率。我们丢弃长度比率最小的 1% 和最大的 5% 的语音，以过滤掉可能存在的异常情况，例如短音频不包含人声但对应长文本转录，或者长音频片段仅包含目标语言的短人声片段，因此对应短文本转录。

3 实验设置

3.1 语音分词器训练数据

使用包含 53 万小时数据的监督式多任务数据集来训练语音分词器，并使用标准化转录作为标签，包括自动语音识别（ASR）、语言识别（LID）、语音情感识别（SER）、音频事件检测（AED）和说话人分析（SA）。训练数据的详细信息列于表 3 中。多语言 ASR 训练数据包含中文、英语、日语、韩语、俄语、法语和德语。

3.2 扩大 CosyVoice 3 的数据集规模和模型规模

在 CosyVoice 3 中，我们从多个方面扩大了数据量。对于广泛使用的中文和英文数据，我们结合使用低成本数据生产流程和自训练数据构建方法，以增强领域、风格、文本格式和罕见

Language	Duration (hours)
Automatic Speech Recognition (ASR) - Multilingual	365K
Language Identification (LID)	85K
Speech Emotion Recognition (SER)	48K
Audio Event Detection (AED)	21K
Speaker analysis	11K

Table 3: 语音分词器训练数据的详细信息。




Figure 3: (a) 七种少数民族语言和 (b) 19 种中文口音或方言的数据百分比。

情况的多样性。在领域多样性方面，我们收集了来自电子商务、导航、金融和教育等各个领域的语音数据。在风格多样性方面，我们增加了对话、演讲、歌唱等多种类型。在文本多样性方面，我们通过文本规范化 (TN) 和逆文本规范化 (ITN) 为同一语音构建不同的文本格式，从而增强模型对不同文本格式的鲁棒性。此外，我们使用自训练方法，利用早期版本的 CosyVoice 3 有策略地创建了大量罕见情况数据，以提高合成稳定性。在语言覆盖方面，我们在中文和英文数据集的基础上增加了七种常用语言，包括日语、俄语、法语、德语、西班牙语、韩语和意大利语，数据占比如图 3a 所示。我们之前的工作 [27] 表明，监督式多任务语音分词器在一些未见过的语言（例如 CosyVoice 3 中的西班牙语和意大利语）上也能表现良好。除了标准的普通话发音外，我们还增加了中文口音和方言的覆盖范围，支持 19 种常用口音或方言，数据占比如图 3b 所示。通过这些数据扩展工作，CosyVoice 3 的训练数据量达到一百万小时，涵盖了日常生活中大多数用户场景，并朝着野外零样本语音生成的目标迈进。

除了扩展数据集规模之外，扩展模型规模对于当前的大型模型也至关重要。因此，我们在 CosyVoice 3 中增加了文本到语音语言模型 (LM) 和条件流匹配 (CFM) 模型的模型大小。具体来说，文本到语音 LM 的参数量从 0.5B 增加到 1.5B。对于 CFM，我们采用最新的扩散 Transformer (DiT) [25,39] 作为骨干网络，将参数量从 100M 增加到 300M。初步实验表明 DiT 架构具有强大的性能；因此，复杂的文本编码器和长度正则化模块不再需要，并已从 CosyVoice 3 中移除。我们通过简单的插值操作解决了语音标记和 Mel 特征之间的帧率不匹配问题。

为了评估 CosyVoice 3 的零样本语音生成能力，我们重点关注三个关键方面：内容一致性、说话人相似度和音频质量。对于内容一致性，我们使用 Whisper-large V3 [40] 进行英语语音识别，使用 Paraformer [41] 进行中文语音识别，并计算语音识别转录结果与给定文本的字符错误率 (CER) 或词错误率 (WER)。为了评估说话人相似度，我们使用 ERes2Net 说话人验证模型 [42] 从生成的语音中提取说话人嵌入，并计算其与参考语音嵌入的余弦相似度。对于音频质量，我们使用 DNSMOS 网络 [43] 对生成的语音进行评分，该评分与人类听觉感知高度相关。

我们在两个测试集上进行评估。第一个是广泛使用的 SEED-TTS-Eval 测试集 [26]，其中测试用例分为普通话、英语和难度较高的中文子集。为了与其他模型进行公平比较，我们还使用基于 WavLM 的说话人识别模型来计算说话人相似度 [44]。值得注意的是，语音生成模型的最新进展使得改进空间很小，各种模型的分数都非常接近；因此，我们引入了一个新的多语言基准测试集 CV3-Eval 进行评估，详情见第 3.3 节。

为了与 CosyVoice 3 进行全面比较，我们使用了 10 个常用的语音生成模型作为基线，这些模型在某些方面达到了最先进的 (SOTA) 或具有竞争力的性能。具体来说，非自回归 (NAR) 模型包括 MaskGCT [15]、E2 TTS [24]、F5-TTS [25] 和 F5R-TTS [37]，而自回归 (AR) 基线模型包括 Seed-TTS [26]、FireRedTTS [29]、Qwen2.5-Omni [45]、CosyVoice [27]、CosyVoice 2 [30] 和 Spark TTS [17]。

3.3 CV3-Eval: 一个多语言基准

随着语音生成模型的快速发展，现有的评估基准已无法满足模型评估的需求，尤其是在零样本语音克隆方面。首先，大多数评估基准（例如 Librispeech [46]）的音频样本来自有声读物，其中说话者的发音清晰标准。因此，一些系统可以轻松合成高质量的音频，甚至超越原始音频。然而，在实际应用场景中，源音频通常包含噪声，而这些基准无法解决这些挑战。其次，大多数基准都是针对中文和英文设计的，缺乏多语言评估基准。最后，传统基准仅关注发音准确性、说话人相似度和音频质量 MOS 分数。这些评估指标无法准确衡量 TTS 系统的综合能力，包括情感表达、节奏丰富度、语音可控性和跨语言语音克隆等方面。

为了更好地评估 CosyVoice 3，我们建立了一个多语言基准 CV3-Eval，其中包括用于客观评估和主观评估的子集。

客观评估。 客观评估子集进一步分为三个子集，包括多语言语音克隆、跨语言语音克隆和情感克隆，如下所示：

- 多语言语音克隆：多语言语音克隆子集包含 9 种语言，每种语言包含 500 个样本，包括中文 (zh)、英文 (en)、日文 (ja)、韩文 (ko)、德文 (de)、法文 (fr)、俄文 (ru)、意大利文 (it) 和西班牙文 (es)。源音频和目标文本样本来自 CommonVoice [47] 和 FLUERS [48] 数据集。为了模拟实际应用场景，我们没有过滤掉包含背景噪声或长时间静音的音频，这给 TTS 系统的鲁棒性带来了挑战。此外，我们构建了两个针对中文和英文的难例测试集，其中目标文本包含生僻词、绕口令、领域特定术语等。
- 跨语言语音克隆。对于跨语言语音克隆子集，源音频和目标文本来自不同的语言，包括中文、英文、日文和韩文。该子集可以评估 TTS 系统的语言迁移能力。
- 情感克隆。情感克隆子集中的音频提示来自 EmoBox [49] 和 SeCap [50]，包括中文和英文样本。由于某些情感标签的表达能力不足，我们仅包含标记为快乐、悲伤或愤怒的样本，每种语言各有 100 个样本。我们根据目标文本是否与目标情感在语义上一致，将这些样本进一步分为文本相关和文本无关两部分。这有助于我们确定合成的情感特征主要来自文本内容还是提示音频。

除了客观评估子集之外，我们还准备了三个主观评估子集，分别用于表达性语音克隆、表达性语音续接和中文口音语音克隆。

- 表达性语音克隆。为了探索模型生成富有表现力语音的能力，表达性语音克隆基准测试旨在包含具有独特特征的音频提示，例如情绪强烈的语调、低语和喊叫，以及极慢或极快的语速。音频提示选自不同的具有挑战性的应用场景，例如新闻、播客、电视剧、学术报告、诗歌朗诵等。我们还对一些公众人物的声音进行了采样以进行评估。
- 表达性语音续接。由于人类感知的可变性很高，对表达性语音克隆进行公平的主观评估具有挑战性。为了缓解这个问题，我们设计了一个语音续接任务。具体来说，我们从网站上选择了 120 个具有不同情感、节奏、速度和音量的音频样本，并将音频剪辑的前 3 秒作为提示语音。因此，我们可以根据合成的剩余语音与真实语音的相似性来评估合成语音。
- 中文口音语音克隆。由于目前尚无可靠的客观方法来评估口音的真实性，我们构建了一个用于中文方言的主观评估数据集。该数据集包含 18 种不同的中文方言，例如粤语、东北话、闽南话、上海话等。所有提示语音样本均来自内部工业数据。

4 实验结果

4.1 SEED-TTS-Eval 上的客观 TTS 结果

Model	test-zh		test-en		test-hard	
	CER (%) ↓	SS ↑	WER (%) ↓	SS ↑	CER (%) ↓	SS ↑
Human	1.26	0.755 (0.775)	2.14	0.734 (0.742)	-	-
Vocoder Resyn.	1.27	0.720	2.17	0.700	-	-
Non-autoregressive Models						
MaskGCT [15]	2.27	0.774 (0.752)	2.62	0.714 (0.730)	10.27	0.748 (0.720)
E2 TTS (32 NFE) [24]	1.97	0.730	2.19	0.710	-	-
F5-TTS (32 NFE) [25]	1.56	0.741 (0.794)	1.83	0.647 (0.742)	8.67	0.713 (0.762)
F5R-TTS [37]	1.37	0.754	-	-	8.79	0.718
Autoregressive Models						
Seed-TTS [26]	1.12	0.796	2.25	0.762	7.59	0.776
FireRedTTS [29]	1.51	0.635 (0.653)	3.82	0.460 (0.526)	17.45	0.621 (0.639)
Qwen2.5-Omni-7B [45]	1.70	0.752	2.72	0.632	7.97	0.747
Qwen2.5-Omni-7B _{RL} [45]	1.42	0.754	2.33	0.641	6.54	0.752
CosyVoice [27]	3.63	0.723 (0.775)	4.29	0.609 (0.699)	11.75	0.709 (0.755)
CosyVoice 2 [30]	1.45	0.748 (0.806)	2.57	0.652 (0.736)	6.83	0.724 (0.776)
Spark TTS [17]	1.20	0.672	1.98	0.584	-	-
CosyVoice 3-0.5B	1.16	0.780 (0.840)	2.02	0.718 (0.790)	6.08	<u>0.758</u> (0.815)
CosyVoice 3-0.5B _{RL}	0.75	0.774 (0.836)	1.76	0.695 (0.783)	5.09	0.750 (0.809)
CosyVoice 3-1.5B	1.12	<u>0.781</u> (0.837)	2.21	<u>0.720</u> (0.789)	5.83	0.758 (0.816)
CosyVoice 3-1.5B _{RL}	0.71	0.775 (0.836)	1.45	0.695 (0.784)	<u>5.66</u>	0.750 (0.810)

Table 4: CosyVoice 3 与基线模型在 SEED 测试集上的零样本 TTS 性能比较，包括内容一致性 (WER/CER) 和说话人相似度 (SS)。对于说话人相似度，括号外的结果由基于 WavLM 的模型测量，而括号内的结果由 ERes2Net 测量。粗体表示最佳结果，underline 表示次佳结果。

表 4 展示了 CosyVoice 3 和几种最新模型在 SEED 测试集上的 TTS 性能，包括中文测试集 test-zh、英文测试集 test-en 和具有挑战性的 test-hard 测试集。评估重点关注内容一致性 (WER/CER) 和说话人相似度 (SS)。

在内容一致性方面，CosyVoice 3 比 CosyVoice 2 有显著提升，在 test-zh 上相对提升了 44%，在 test-en 上相对提升了 51%。在 test-hard 测试集中，CosyVoice 3 将 CER 从 6.83% 降低到 5.09% (相对提升 26%)。与其他基线模型相比，CosyVoice 3 在所有指标上都表现出色。值得注意的是，CosyVoice 3-1.5B_{RL} 在 test-zh 中记录了最低的 CER (0.71%)，在 test-en 中记录了最低的 WER (1.45%)，展现了其卓越的合成精度。在极具挑战性的测试场景下，CosyVoice 3-0.5B_{RL} 实现了最低的字符错误率 (CER)，为 5.09%，而 1.5B 版本紧随其后，CER 为 5.66%。较大模型性能不如较小模型的原因在于用于预训练和后训练的数据集有限，尤其是在具有挑战性的场景下。我们计划将数据集扩展到数千万小时，以支持未来更大模型的更有效训练。

在说话人相似度方面，CosyVoice 3 展现出准确复制说话人特征的强大能力。它在 WavLM 和 ERes2Net 两种指标下均优于 CosyVoice 2 和其他基线模型 (Seed-TTS 除外)。CosyVoice 3 和 Seed-TTS 之间的相似度差距主要源于说话人多样性和预训练数据量的差异。未来我们将通过扩大预训练数据量来提高 CosyVoice 3 的说话人相似度。此外，表 4 显示，强化学习后训练使内容一致性相对提高了 12% 到 35%，增强了多语言和复杂合成任务的鲁棒性和适应性。通过强化学习后训练，CosyVoice 3 在文本转语音 (TTS) 性能方面树立了新的标杆，展现出比以往模型显著的进步。

4.2 多语言基准测试 CV3-Eval 的客观评估

4.2.1 多语言语音克隆结果

我们使用 CV3-Eval 基准测试的多语言语音克隆子集，对 CosyVoice 3 与其他具有竞争力的开源 TTS 系统 (包括 F5-TTS、Spark-TTS 和 GPT-SoVits¹) 进行了评估。表 5 提供了中文、日文和韩文的 CER，以及英文、德文、西班牙文、法文、意大利文和俄文的词错误

¹<https://github.com/RVC-Boss/GPT-SoVITS>

Model	zh	en	ja	ko	de	es	fr	it	ru
F5-TTS	5.47	8.90	–	–	–	–	–	–	–
Spark-TTS	5.15	11.0	–	–	–	–	–	–	–
GPT-SoVits	7.34	12.5	–	–	–	–	–	–	–
CosyVoice2	4.08	6.32	9.13	19.7	–	–	–	–	–
+ DiffRO	3.00	4.72	6.36	5.14	–	–	–	–	–
CosyVoice3-0.5B	3.89	5.24	10.4	12.8	7.41	4.25	12.9	6.68	6.77
+ DiffRO	2.89	3.68	5.15	4.02	4.51	2.99	8.56	2.94	3.79
CosyVoice3-1.5B	3.91	4.99	7.57	5.69	6.43	4.47	11.8	10.5	6.64
+ DiffRO	3.01	3.71	5.27	4.01	3.93	3.26	8.09	2.72	4.11

Table 5: CV3-Eval 多语言语音克隆子集上的 CER(%) 和 WER(%)。– 表示该语言不受支持。

Model	hard-zh			hard-en		
	WER	SS	DNSMOS	WER	SS	DNSMOS
CosyVoice2	12.58	72.6	3.81	11.96	66.7	3.95
+ DiffRO	10.66	71.7	3.81	10.25	62.4	3.97
CosyVoice3-0.5B	14.15	78.6	3.75	9.04	75.9	3.92
+ DiffRO	8.26	77.8	3.80	7.60	73.9	3.95
CosyVoice3-1.5B	9.77	78.5	3.79	10.55	76.1	3.95
+ DiffRO	9.06	78.2	3.81	7.56	74.6	3.95

Table 6: CV3-Eval 多语言语音克隆子集中的难样本上的 WER(%)、说话人相似度(SS) 和 MOS 分数。

率(WER)。多语言语音克隆子集极具挑战性，CosyVoice 3 是唯一能够涵盖该子集中所有语言的系统。对于大多数语言，CosyVoice3-0.5B 和 CosyVoice3-1.5B 之间的性能差异很小。此外，如表 6 所示，CosyVoice 3 在生成僻词、绕口令以及特定领域术语方面仍然存在困难，这表明未来仍有改进空间。

4.2.2 跨语言语音克隆结果

表 7 展示了 CosyVoice 3 在跨语言语音克隆方面相对于 CosyVoice 2 的显著改进。值得注意的是，由于两种语言的字符重叠，CosyVoice 2 在将日语语音转换为中文语音时表现不佳，而 CosyVoice 3 通过将所有日语字符转换为假名解决了这个问题。此外，扩大模型规模也带来了益处：与 CosyVoice3-0.5B 相比，CosyVoice3-1.5B 在所有条件下都展现出更好的 WER（词错误率），同时保持了相似的说话人相似度。这表明更大的模型由于容量增加，可以提高在具有挑战性任务上的性能。

由于大多数开源 TTS 系统仅支持中文和英文，我们进一步评估了 CosyVoice 3 在 zh2en 和 en2zh 跨语言语音克隆任务上的性能，并将其与基线模型进行比较，如表 8 所示。与 CosyVoice 3 相比，F5-TTS 和 Spark-TTS 的 WER 性能较差，其中 Spark-TTS 的 SS（说话人相似度）也明显低于 F5-TTS 和 CosyVoice 3。在 MOS 分数方面，CosyVoice 3 在 en2zh 任务上表现更好，在 zh2en 任务上表现相当。总体而言，CosyVoice3-1.5B 仍然是 zh2en 和 en2zh 跨语言转换任务的最佳模型。

4.2.3 情感语音克隆结果

在 CV3-Eval 情感语音克隆子集中，我们使用 emo2vec-large-plus 模型² 作为分类器来评估 TTS 系统的情感表达能力。表 9 中显示的结果表明，大多数 TTS 系统在文本相关子集上表现良好，其中 CosyVoice 3 的性能最高。每个系统都擅长表达特定的情感，其中“快乐”是所有模型中最容易表达的情感。然而，在文本无关的任务中，情感准确率显著下降，尤其是在“悲伤”和“愤怒”的情感方面。这表明 TTS 系统主要从文本情感中推断输出音频的情感基调。这项观察为性能不佳之处提供了宝贵的见解，并指出了未来需要改进的领域。

²https://www.modelscope.cn/models/iic/emotion2vec_plus_large/summary

Model	to-zh			to-en			to-ja			to-ko		
	en	ja	ko	zh	ja	ko	zh	en	ko	zh	en	ja
CosyVoice2	13.5	48.1	7.70	6.47	17.1	11.2	13.1	14.9	5.86	24.8	21.9	21.5
CosyVoice3-0.5B	8.48	6.86	5.24	4.99	6.83	5.86	18.3	16.8	4.99	41.0	20.4	12.8
+ DiffRO	5.16	3.22	1.03	3.40	4.41	4.78	7.91	7.25	3.29	16.9	11.6	8.2
CosyVoice3-1.5B	8.01	6.78	3.30	4.32	5.39	5.94	13.7	13.4	4.19	31.6	14.0	10.5
+ DiffRO	5.09	3.05	1.06	2.98	4.20	4.19	7.08	6.80	3.93	14.4	5.87	7.92

Table 7: CV3-Eval 跨语言语音克隆子集上的 WER(%) 结果。

Model	en2zh			zh2en		
	WER	SS	MOS	WER	SS	MOS
F5-TTS	11.6	64.2	3.77	5.57	64.7	3.77
Spark-TTS	12.4	48.4	3.65	7.36	56.7	3.61
CosyVoice2	13.5	63.3	3.87	6.47	64.3	3.75
CosyVoice3-0.5B	8.48	67.4	3.82	4.99	67.8	3.75
CosyVoice3-1.5B	8.01	66.9	3.83	4.32	66.4	3.77

Table 8: CosyVoice 3 和基线模型在 zh2en 和 en2zh 语音克隆任务上的 WER(%)、说话人相似度(SS) 和 MOS 分数。

Model	Text-Related			Text-Unrelated		
	happy	sad	angry	happy	sad	angry
F5-TTS	0.92	0.52	0.72	0.80	0.28	0.64
Sparks-TTS	0.80	0.56	0.50	0.50	0.60	0.36
GPT-SoVits	0.88	0.54	0.50	0.48	0.40	0.30
CosyVoice2	0.84	0.72	0.58	0.56	0.44	0.38
CosyVoice3-0.5B	0.92	0.70	0.72	0.64	0.42	0.58
CosyVoice3-1.5B	0.86	0.64	0.72	0.64	0.44	0.48
+ DiffRO-EMO	0.98	0.68	0.84	0.98	0.50	0.68

Table 9: CV3-Eval 情感语音克隆子集的文本相关和文本无关子集上的情感准确率。

4.2.4 主观评估结果

除了客观指标外，我们还使用平均意见得分 (MOS) 进行了主观评估。测试样本包含 200 个中文和英文句子，每个句子由 10 位母语人士 (5 男 5 女) 进行评估。分数范围为 1 到 5，以 0.5 分为增量。图 4 显示了 CosyVoice 2、CosyVoice 3-0.5B 和 CosyVoice 3-1.5B 模型在两种语言上的 MOS 分数及其平均分数。

在中文方面，所有三个模型的表现相似，但仍然落后于人类语音。在英文方面，CosyVoice 2 的得分低于人类基准，CosyVoice 3-0.5B 的得分与人类得分持平，而 CosyVoice 3-1.5B 的得分明显更高。总体而言，CosyVoice 3-1.5B 的性能优于 CosyVoice 3-0.5B，两者都优于 CosyVoice 2，这表明数据和模型扩展的优势。

尽管与人类语音在中文方面存在一些差异，但 CosyVoice 3 模型的得分仍然高于 4.45。这种差距主要是由于合成输出中一些低分案例与真实语音相比造成的，这表明未来工作中需要提高合成稳定性。

4.3 语音分词器消融实验

4.3.1 上游识别任务

我们基于监督式多任务学习的语音分词器在各种语音和声音任务中表现出色。具体而言，如表 10 所示，CosyVoice 3 中基于 FSQ-MinMo 的语音分词器有效地保持了多语言自动语音识别 (ASR) 能力。通过在 FSQ-MinMo 中仅关注与语音相关的任务，并将其他任务从训练集中排除，我们在 Fluers CN 测试集上实现了优于 MinMo 的识别性能。此外，表 11 表明，




Figure 4: 零样本克隆模型在中文、英文及其平均值上的平均意见得分 (MOS)。

Method	C.V. EN	C.V. CN	C.V. JA	C.V. KO	Fluers EN	Fluers CN
SenseVoice	7.70	8.67	-	-	4.57	6.98
MinMo	7.36	8.56	-	-	4.43	6.71
VQ-SenseVoice	18.26	11.56	-	-	7.65	5.03
FSQ-SenseVoice	10.67	7.29	-	-	6.58	4.43
FSQ-MinMo	11.36	9.21	13.90	9.78	4.46	3.35

Table 10: 在 CommonVoice (C.V.) 和 Fluers 基准测试的特定语言子集上，比较 Sensevoice-large 和 MinMo 编码器中 VQ 和 FSQ 在 ASR WER 和 CER 方面的性能 (%)。FSQ-MinMo 是 CosyVoice 3 中使用的分词器。

FSQ-MinMo 模型在 AIR-Bench 基准测试中的表现与 MinMo 模型相当，该基准测试包含语言识别、性别、年龄、情感、人声和声音问题分类等任务。

4.3.2 下游 TTS 任务

除了上游识别任务之外，我们还在下游 TTS 任务中评估了分词器，通过用其他分词器的 token 替换 CosyVoice 3 的 token，并保持 LM 和 CFM 的模型架构不变，直接评估合成性能。表 12 显示了在两个不同规模数据集（3000 小时和 170000 小时）上训练的各种模型的结果。除了我们监督式语义分词器 CosyVoice 2.0³ 和 CosyVoice 3.0 之外，我们还评估了其他 TTS 模型中广泛使用的自监督分词器 HuBERT⁴ 和 W2v-BERT 2.0⁵。此外，我们还引入了无监督分词器 SoundStream⁶，它通过基于残差向量量化的变分自编码器 (RVQ-VAE)

³<https://github.com/FunAudioLLM/CosyVoice>

⁴<https://github.com/facebookresearch/fairseq/tree/main/examples/hubert>

⁵https://huggingface.co/amphion/MaskGCT/tree/main/semantic_codec

⁶https://huggingface.co/amphion/MaskGCT/tree/main/acoustic_codec

Method	Language ID	Gender	Age	Emotion	Vocal Sound	Sound Question
MinMo	99.2	84.8	70.1	62.4	90.7	59.1
FSQ-MinMo	99.2	72.8	41.8	68.4	61.3	57.7

Table 11: MinMo 和 FSQ-MinMo 模型在 AIR-Bench 基准测试中的准确率性能比较，包括语言识别、性别、年龄、情感、人声和声音问答分类任务。

Model	test-zh		test-en		test-hard	
	CER (%) ↓	SS ↑	WER (%) ↓	SS ↑	CER (%) ↓	SS ↑
3000-hour Dataset						
SoundStream(1 st VQ) [51]	14.19	0.457	25.34	0.301	27.05	0.455
HuBERT [52]	18.68	0.716	6.50	0.609	33.83	0.699
W2v-BERT 2.0 [53]	2.62	0.381	6.72	0.261	23.89	0.374
CosyVoice 2.0 [30]	1.92	0.668	7.21	0.535	15.99	0.645
CosyVoice 3.0-0.5B	1.68	0.710	6.60	0.614	27.60	0.679
170,000-hour Dataset						
CosyVoice 2.0 [30]	1.45	0.806	2.57	0.736	6.83	0.776
CosyVoice 3.0-0.5B	1.27	0.815	2.46	0.747	6.96	0.787

Table 12: 使用不同分词器在 SEED 测试集上进行下游零样本 TTS 建模的性能比较，比较指标包括内容一致性（WER/CER）和说话人相似度（SS）。粗体表示最佳结果。

将声波量化为离散 token 组。由于其他分词器只有一个码本，因此仅使用 SoundStream 的第一个 VQ 组进行比较。

在 3000 小时的数据集上，有监督语义分词器展现出与 HuBERT 相似的说话人相似度，同时显著优于 W2v-BERT 2.0。这是因为 HuBERT 和有监督语义分词器都专注于语义信息，最大限度地减少声学干扰，而 W2v-BERT 2.0 由于其训练方法，保留了所有上下文信息，包括语义信息和声学信息。这使得条件流匹配模型能够更好地强调参考语音的声学特征，同时忽略语音标记中的声学干扰。在内容一致性方面，有监督分词器在 test-zh 数据集上实现了最低的 CER，并在 test-en 和 test-hard 数据集上取得了可比的性能。HuBERT 在 test-zh 数据集上较高的 CER 突出表明了其语言特异性限制。正如预期的那样，SoundStream 的声学标记在所有评估的测试集上都取得了较高的错误率，表明其与合成文本的内容一致性较差。这是因为这些声学标记既不像自监督标记那样尝试建模上下文信息，也不像有监督标记那样与文本对齐，导致缺乏足够的语义信息。

将训练数据量从 3000 小时增加到 17 万小时，可以显著提高内容一致性和说话人相似度，尤其是在英语和具有挑战性的场景下，相对 WER/CER 改进幅度从 63% 到 75% 不等。如表 4 所示，将数据集进一步扩展到一百万小时可以提高性能，但改进速度开始趋于平缓。这表明我们的多任务有监督分词器具有可扩展性，并且可以从更大的数据集中受益，但存在收益递减的临界点。

4.4 强化学习消融实验

我们的实验表明，DiffRO 显著提升了文本转语音（TTS）系统的性能，包括 CosyVoice 2 和 CosyVoice 3。如表 4、5 和 7 所示，DiffRO 在词错误率（WER）方面实现了 20% 到 50% 的相对提升。在资源匮乏的语言和跨语言场景中，性能提升尤为显著，在半数情况下，相对 WER 提升超过 50%；值得注意的是，CosyVoice 3-0.5B 在韩语上的相对提升高达 68.7%。此外，强化学习训练缩小了 0.5B 和 1.5B 模型之间的性能差距。

关于说话人相似度，RL 在大多数数据集上略微降低了说话人相似度，尽管变化很小。这表明 DiffRO 中仍然存在“过度优化”问题，模型更侧重于目标奖励，可能会忽略其他指标。将说话人相似度模块作为奖励任务引入可以缓解这个问题，但可能会增加 WER。此外，将 SER 任务作为奖励模型旨在增强 CosyVoice 3 的情感表达能力。表 9 显示，DiffRO-EMO 使 CosyVoice3-1.5B 在文本相关和文本无关任务中都能在大多数情感上实现最高的准确率。然而，情感表达的这种改进可能会对发音产生不利影响，这凸显了在 DiffRO 中平衡奖励的挑战，我们将在未来的工作中解决这个问题。

此外，如表 6 所示，DiffRO 在困难样本测试集上的 WER、SS 和 DNSMOS 改进不如在整体测试集上的改进明显。这可能是因为困难样本包含生僻词、绕口令词和重复词，这些对奖励模型构成了重大挑战。

Method	zh			en		
	Errors	Corrections	Rate(%)	Errors	Corrections	Rate(%)
RepAll + MixPhn	13	9	69.2	11	8	72.7
RepMono + MixPhn	15	15	100	9	9	100
RepMono + CatPhn	15	13	86.7	8	8	100

Table 13: 发音修复的纠错率。

4.5 发音修复

我们构建了一个评估集来比较不同的发音修复方法，重点关注中文多音字和英文多音词的挑战性案例。校正率用作评估修复能力的指标。如表 10 所示，最佳方法实现了 100% 的校正率。

“RepAll”方法涉及将所有汉字和英文单词都视为潜在的替换对象，并在训练数据增强期间使用内部 G2P 模型进行音素预测。虽然这种方法提供了广泛的字符-音素组合覆盖，但由于 G2P 预测会引入不匹配。相反，“RepMono”仅替换单音字或单词，从而确保训练集的准确性。

“CatPhn”和“MixPhn”之间的关键区别在于是否保留汉字并将其与音素表示连接起来，还是仅用音素替换汉字。“CatPhn”保留了语义完整性，但要求模型优先考虑音素表示而不是字符，当仅考虑单音字时，这种情况会更加突出。为了缓解这个问题，我们引入了一些噪声数据，例如用发音不同的字符替换某个字符，同时保留正确的音素表示。然而，使用“MixPhn”实现具有竞争力的纠错率仍然具有挑战性。

我们使用 Expresso 数据集和内部表达性数据集来评估指令生成功能的有效性。Expresso 数据集是一个多说话人表达性语音集合，包含八种不同的说话风格，并在 3000 个样本的子集上进行评估。我们的内部数据集包含 3600 个样本，与指令遵循训练数据集的领域相匹配，涵盖 50 多种不同的情绪、语速、方言、口音和角色扮演说话风格。

评估结果如表 14 所示。CosyVoice 3 在风格相似性方面表现出显著改进，比其前身提高了约 11%。在内容一致性方面，CosyVoice 3 在 Expresso 测试集上的 WER 较高，但在我们的内部测试集上的 WER 较低。这种差异主要是由于 ASR 模型偏向标准发音而非情感发音，这体现在与 CosyVoice 2 相比，真实语音的 WER 更高。客观评估情感语音的内容一致性仍然是一个具有挑战性的问题。

虽然我们已经通过指令生成探索了各种风格，但尚未包含歌唱，这将在未来的工作中解决。目前，CosyVoice 3 的指令生成专注于情感、语速和风格，主要与语言模型 (LM) 相关。音色与条件流匹配 (CFM) 更密切相关，目前尚未考虑。使用自然语言或其他模态编辑音色是一个有前景但尚未充分探索的领域。

Model	Expresso			Internal Dataset		
	WER	SIM	MOS	WER	SIM	MOS
GroundTruth	10.0	100	3.65	8.98	100	3.47
CosyVoice 2	9.42	60.98	3.54	7.75	72.99	3.53
CosyVoice 3-0.5B	13.72	67.82	3.56	7.30	80.45	3.51
CosyVoice 3-1.5B	13.43	68.25	3.56	7.31	81.06	3.51

Table 14: 不同模型在指令式 TTS 任务上的 WER (%)、风格相似性 (SIM) 和 MOS 分数比较。

为了确保 SFT 模型中的音色一致性，我们采用无监督聚类方法来识别每个说话者的音色中心。然后，这些聚类中心被用作条件流匹配模型中的说话者嵌入。如图 5 所示，增加训练数据的数量和多样性，以及升级语音标记，可以降低微调模型的错误率，尤其是在 test-en 和 test-hard 数据集上表现更为显著。这表明改进基础模型也能使说话者微调模型受益。




Figure 5: CosyVoice 3 和 CosyVoice 2 SFT 模型在 SEED-TTS-Eval 设置下的内容一致性结果。test-en 数据集使用词错误率 (WER)，其他数据集使用字符错误率 (CER)。




Figure 6: CosyVoice 3 将单语说话者转换为多语说话者的内容一致性结果。中文、韩语和日语使用字符错误率 (CER)，其他语言使用词错误率 (WER)。

4.6 将单语说话者转换为多语说话者的结果

在我们的实验中，我们旨在利用第 2.1.1 节描述的训练过程将单语说话者转换为多语说话者。如图 6 所示，中文、英语、德语、西班牙语、法语、意大利语和俄语等语言的 CER/WER 均低于 4%，这表明我们的持续训练方法是有效的。

然而，日语的字符错误率较高，约为 9%，这主要归因于两个因素：语音合成前将汉字转换为假名会引入额外的错误，以及日语字符的多种发音增加了复杂性。对于韩语，CER 约为 6%，这主要是由于可用数据的数量和质量有限。我们将在未来的工作中扩展韩语数据集。

5 结论

总之，本报告介绍了 CosyVoice 3，这是一款专为实际应用场景量身定制的先进零样本语音合成模型。通过扩展数据和模型参数，CosyVoice 3 克服了以往在语言覆盖范围和合成质量方面的局限性，实现了卓越的内容一致性、说话人相似度和语调自然度。我们的一些创新，包括新型语音分词器和后训练策略，增强了模型捕捉复杂副语言细节的能力。CosyVoice 3 在多个基准测试中取得了最先进的成果，代表着语音合成领域的重大进步，为在各种现实场景中实现更通用、更高质量的语音生成铺平了道路。

6 局限性

CosyVoice 3 存在一些局限性，需要在未来的工作中加以解决。CosyVoice 3 无法通过文本指令控制音色等声学特征，这对于角色扮演应用来说是一个有趣且有价值的探索方向。此外，CosyVoice 3 在生成歌声方面表现不佳。可以通过在分词器和语言模型的训练阶段添加歌唱数据来改进这一点。

References

- [1] Yuxuan Wang, R. J. Skerry-Ryan, Daisy Stanton, Yonghui Wu, Ron J. Weiss, Navdeep Jaitly, Zongheng Yang, Ying Xiao, Zhifeng Chen, Samy Bengio, Quoc V. Le, Yannis Agiomyrgiannakis, Rob Clark, and Rif A. Saurous. Tacotron: Towards end-to-end speech synthesis. In INTERSPEECH, pages 4006–4010. ISCA, 2017.
- [2] Jonathan Shen, Ruoming Pang, Ron J. Weiss, Mike Schuster, Navdeep Jaitly, Zongheng Yang, Zhifeng Chen, Yu Zhang, Yuxuan Wang, R. J. Skerry-Ryan, Rif A. Saurous, Yannis Agiomyrgiannakis, and Yonghui Wu. Natural TTS synthesis by conditioning wavenet on MEL spectrogram predictions. In ICASSP, pages 4779–4783. IEEE, 2018.
- [3] Wei Ping, Kainan Peng, Andrew Gibiansky, Sercan Ömer Arik, Ajay Kannan, Sharan Narang, Jonathan Raiman, and John Miller. Deep voice 3: 2000-speaker neural text-to-speech. CoRR, abs/1710.07654, 2017.
- [4] Wei Ping, Kainan Peng, and Jitong Chen. Clarinet: Parallel wave generation in end-to-end text-to-speech. In ICLR (Poster). OpenReview.net, 2019.
- [5] Yi Ren, Yangjun Ruan, Xu Tan, Tao Qin, Sheng Zhao, Zhou Zhao, and Tie-Yan Liu. FastSpeech: Fast, robust and controllable text to speech. In NeurIPS, pages 3165–3174, 2019.
- [6] Naihan Li, Shujie Liu, Yanqing Liu, Sheng Zhao, and Ming Liu. Neural speech synthesis with transformer network. In AAAI, pages 6706–6713. AAAI Press, 2019.
- [7] Yi Ren, Chenxu Hu, Xu Tan, Tao Qin, Sheng Zhao, Zhou Zhao, and Tie-Yan Liu. FastSpeech 2: Fast and high-quality end-to-end text to speech. In ICLR. OpenReview.net, 2021.
- [8] Chengyi Wang, Sanyuan Chen, Yu Wu, Ziqiang Zhang, Long Zhou, Shujie Liu, Zhuo Chen, Yanqing Liu, Huaming Wang, Jinyu Li, Lei He, Sheng Zhao, and Furu Wei. Neural codec language models are zero-shot text to speech synthesizers. CoRR, abs/2301.02111, 2023.
- [9] Eugene Kharitonov, Damien Vincent, Zalán Borsos, Raphaël Marinier, Sertan Girgin, Olivier Pietquin, Matt Sharifi, Marco Tagliasacchi, and Neil Zeghidour. Speak, read and prompt: High-fidelity text-to-speech with minimal supervision. Trans. Assoc. Comput. Linguistics, 11:1703–1718, 2023.
- [10] Yakun Song, Zhuo Chen, Xiaofei Wang, Ziyang Ma, and Xie Chen. ELLA-V: stable neural codec language modeling with alignment-guided sequence reordering. CoRR, abs/2401.07333, 2024.
- [11] Chenpeng Du, Yiwei Guo, Hankun Wang, Yifan Yang, Zhikang Niu, Shuai Wang, Hui Zhang, Xie Chen, and Kai Yu. VALL-T: decoder-only generative transducer for robust and decoding-controllable text-to-speech. CoRR, abs/2401.14321, 2024.

- [12] Detai Xin, Xu Tan, Kai Shen, Zeqian Ju, Dongchao Yang, Yuancheng Wang, Shinnosuke Takamichi, Hiroshi Saruwatari, Shujie Liu, Jinyu Li, and Sheng Zhao. RALL-E: robust codec language modeling with chain-of-thought prompting for text-to-speech synthesis. CoRR, abs/2404.03204, 2024.
- [13] Sanyuan Chen, Shujie Liu, Long Zhou, Yanqing Liu, Xu Tan, Jinyu Li, Sheng Zhao, Yao Qian, and Furu Wei. VALL-E 2: Neural codec language models are human parity zero-shot text to speech synthesizers. CoRR, abs/2406.05370, 2024.
- [14] Bing Han, Long Zhou, Shujie Liu, Sanyuan Chen, Lingwei Meng, Yanming Qian, Yanqing Liu, Sheng Zhao, Jinyu Li, and Furu Wei. VALL-E R: robust and efficient zero-shot text-to-speech synthesis via monotonic alignment. CoRR, abs/2406.07855, 2024.
- [15] Yuancheng Wang, Haoyue Zhan, Liwei Liu, Ruihong Zeng, Haotian Guo, Jiachen Zheng, Qiang Zhang, Shunsi Zhang, and Zhizheng Wu. Maskgct: Zero-shot text-to-speech with masked generative codec transformer. CoRR, abs/2409.00750, 2024.
- [16] Lingwei Meng, Long Zhou, Shujie Liu, Sanyuan Chen, Bing Han, Shujie Hu, Yanqing Liu, Jinyu Li, Sheng Zhao, Xixin Wu, Helen Meng, and Furu Wei. Autoregressive speech synthesis without vector quantization. CoRR, abs/2407.08551, 2024.
- [17] Xinsheng Wang, Mingqi Jiang, Ziyang Ma, Ziyu Zhang, Songxiang Liu, Linqin Li, Zheng Liang, Qixi Zheng, Rui Wang, Xiaoqin Feng, et al. Spark-tts: An efficient llm-based text-to-speech model with single-stream decoupled speech tokens. arXiv preprint arXiv:2503.01710, 2025.
- [18] Matthew Le, Apoorv Vyas, Bowen Shi, Brian Karrer, Leda Sari, Rashel Moritz, Mary Williamson, Vimal Manohar, Yossi Adi, Jay Mahadeokar, and Wei-Ning Hsu. Voicebox: Text-guided multilingual universal speech generation at scale. In NeurIPS, 2023.
- [19] Zeqian Ju, Yuancheng Wang, Kai Shen, Xu Tan, Detai Xin, Dongchao Yang, Eric Liu, Yichong Leng, Kaitao Song, Siliang Tang, Zhizheng Wu, Tao Qin, Xiangyang Li, Wei Ye, Shikun Zhang, Jiang Bian, Lei He, Jinyu Li, and Sheng Zhao. Naturalspeech 3: Zero-shot speech synthesis with factorized codec and diffusion models. In ICML. OpenReview.net, 2024.
- [20] Yiwei Guo, Chenpeng Du, Ziyang Ma, Xie Chen, and Kai Yu. Voiceflow: Efficient text-to-speech with rectified flow matching. In ICASSP, pages 11121–11125. IEEE, 2024.
- [21] Shivam Mehta, Ruibo Tu, Jonas Beskow, Éva Székely, and Gustav Eje Henter. Matcha-tts: A fast TTS architecture with conditional flow matching. In ICASSP, pages 11341–11345. IEEE, 2024.
- [22] Yuan Gao, Nobuyuki Morioka, Yu Zhang, and Nanxin Chen. E3 TTS: easy end-to-end diffusion-based text to speech. In ASRU, pages 1–8. IEEE, 2023.
- [23] Keon Lee, Dong Won Kim, Jaehyeon Kim, and Jaewoong Cho. Ditto-tts: Efficient and scalable zero-shot text-to-speech with diffusion transformer. CoRR, abs/2406.11427, 2024.
- [24] Sefik Emre Eskimez, Xiaofei Wang, Manthan Thakker, Canrun Li, Chung-Hsien Tsai, Zhen Xiao, Hemin Yang, Zirun Zhu, Min Tang, Xu Tan, Yanqing Liu, Sheng Zhao, and Naoyuki Kanda. E2 TTS: embarrassingly easy fully non-autoregressive zero-shot TTS. CoRR, abs/2406.18009, 2024.
- [25] Yushen Chen, Zhikang Niu, Ziyang Ma, Keqi Deng, Chunhui Wang, Jian Zhao, Kai Yu, and Xie Chen. F5-TTS: A fairytaler that fakes fluent and faithful speech with flow matching. CoRR, abs/2410.06885, 2024.
- [26] Philip Anastassiou, Jiawei Chen, Jitong Chen, Yuanzhe Chen, Zhuo Chen, Ziyi Chen, Jian Cong, Lelai Deng, Chuang Ding, Lu Gao, Mingqing Gong, Peisong Huang, Qingqing Huang, Zhiying Huang, Yuanyuan Huo, Dongya Jia, Chumin Li, Feiya Li, Hui Li, Jiabin Li, Xiaoyang Li, Xingxing Li, Lin Liu, Shouda Liu, Sichao Liu, Xudong Liu, Yuchen Liu, Zhengxi Liu, Lu Lu, Junjie Pan, Xin Wang, Yuping Wang, Yuxuan Wang, Zhen Wei, Jian Wu, Chao Yao, Yifeng Yang, Yuanhao Yi, Junteng Zhang, Qidi Zhang, Shuo Zhang, Wenjie Zhang, Yang Zhang, Zilin Zhao, Dejian Zhong, and Xiaobin Zhuang. Seed-tts: A family of high-quality versatile speech generation models. CoRR, abs/2406.02430, 2024.

- [27] Zhihao Du, Qian Chen, Shiliang Zhang, Kai Hu, Heng Lu, Yexin Yang, Hangrui Hu, Siqi Zheng, Yue Gu, Ziyang Ma, Zhifu Gao, and Zhijie Yan. Cosyvoice: A scalable multilingual zero-shot text-to-speech synthesizer based on supervised semantic tokens. CoRR, abs/2407.05407, 2024.
- [28] Xingchen Song, Mengtao Xing, Changwei Ma, Shengqiang Li, Di Wu, Binbin Zhang, Fuping Pan, Dinghao Zhou, Yuekai Zhang, Shun Lei, et al. Touchtts: An embarrassingly simple tts framework that everyone can touch. arXiv preprint arXiv:2412.08237, 2024.
- [29] Haohan Guo, Kun Liu, Feiyu Shen, Yi-Chen Wu, Feng-Long Xie, Kun Xie, and Kaituo Xu. Fireredtts: A foundation text-to-speech framework for industry-level generative speech applications. CoRR, abs/2409.03283, 2024.
- [30] Zhihao Du, Yuxuan Wang, Qian Chen, Xian Shi, Xiang Lv, Tianyu Zhao, Zhifu Gao, Yexin Yang, Changfeng Gao, Hui Wang, et al. Cosyvoice 2: Scalable streaming speech synthesis with large language models. arXiv preprint arXiv:2412.10117, 2024.
- [31] Dongya Jia, Zhuo Chen, Jiawei Chen, Chenpeng Du, Jian Wu, Jian Cong, Xiaobin Zhuang, Chumin Li, Zhen Wei, Yuping Wang, et al. Ditar: Diffusion transformer autoregressive modeling for speech generation. arXiv preprint arXiv:2502.03930, 2025.
- [32] Wei Deng, Siyi Zhou, Jingchen Shu, Jinchao Wang, and Lu Wang. Indextts: An industrial-level controllable and efficient zero-shot text-to-speech system. arXiv preprint arXiv:2502.05512, 2025.
- [33] Qian Chen, Yafeng Chen, Yanni Chen, Mengzhe Chen, Yingda Chen, Chong Deng, Zhihao Du, Ruize Gao, Changfeng Gao, Zhifu Gao, et al. Minmo: A multimodal large language model for seamless voice interaction. arXiv preprint arXiv:2501.06282, 2025.
- [34] Fabian Mentzer, David Minnen, Eirikur Agustsson, and Michael Tschannen. Finite scalar quantization: VQ-VAE made simple. In ICLR. OpenReview.net, 2024.
- [35] Tongyi Speech Team. Funaudiollm: Voice understanding and generation foundation models for natural interaction between humans and llms. arxiv, 2024.
- [36] Jianlin Su, Murtadha H. M. Ahmed, Yu Lu, Shengfeng Pan, Wen Bo, and Yunfeng Liu. Roformer: Enhanced transformer with rotary position embedding. Neurocomputing, 568:127063, 2024.
- [37] Xiaohui Sun, Ruitong Xiao, Jianye Mo, Bowen Wu, Qun Yu, and Baoxun Wang. F5r-tts: Improving flow matching based text-to-speech with group relative policy optimization. arXiv preprint arXiv:2504.02407, 2025.
- [38] An Yang, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chengyuan Li, Dayiheng Liu, Fei Huang, Haoran Wei, et al. Qwen2. 5 technical report. arXiv preprint arXiv:2412.15115, 2024.
- [39] William Peebles and Saining Xie. Scalable diffusion models with transformers. In Proceedings of the IEEE/CVF international conference on computer vision, pages 4195–4205, 2023.
- [40] Alec Radford, Jong Wook Kim, Tao Xu, Greg Brockman, Christine McLeavey, and Ilya Sutskever. Robust speech recognition via large-scale weak supervision. In Andreas Krause, Emma Brunskill, Kyunghyun Cho, Barbara Engelhardt, Sivan Sabato, and Jonathan Scarlett, editors, International Conference on Machine Learning, ICML 2023, 23-29 July 2023, Honolulu, Hawaii, USA, volume 202 of Proceedings of Machine Learning Research, pages 28492–28518. PMLR, 2023.
- [41] Zhifu Gao, Zerui Li, Jiaming Wang, Haoneng Luo, Xian Shi, Mengzhe Chen, Yabin Li, Lingyun Zuo, Zhihao Du, Zhangyu Xiao, et al. Funasr: A fundamental end-to-end speech recognition toolkit. arXiv preprint arXiv:2305.11013, 2023.
- [42] Yafeng Chen, Siqi Zheng, Hui Wang, Luyao Cheng, Qian Chen, and Jiajun Qi. An enhanced res2net with local and global feature fusion for speaker verification. arXiv preprint arXiv:2305.12838, 2023.

- [43] Chandan K. A. Reddy, Vishak Gopal, and Ross Cutler. Dnsmos P.835: A non-intrusive perceptual objective speech quality metric to evaluate noise suppressors. In ICASSP, pages 886–890. IEEE, 2022.
- [44] Zhengyang Chen, Sanyuan Chen, Yu Wu, Yao Qian, Chengyi Wang, Shujie Liu, Yanmin Qian, and Michael Zeng. Large-scale self-supervised speech representation learning for automatic speaker verification. In ICASSP 2022-2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), pages 6147–6151. IEEE, 2022.
- [45] Jin Xu, Zhifang Guo, Jinzheng He, Hangrui Hu, Ting He, Shuai Bai, Keqin Chen, Jialin Wang, Yang Fan, Kai Dang, et al. Qwen2. 5-omni technical report. arXiv preprint arXiv:2503.20215, 2025.
- [46] Vassil Panayotov, Guoguo Chen, Daniel Povey, and Sanjeev Khudanpur. Librispeech: an asr corpus based on public domain audio books. In 2015 IEEE international conference on acoustics, speech and signal processing (ICASSP), pages 5206–5210. IEEE, 2015.
- [47] Rosana Ardila, Megan Branson, Kelly Davis, Michael Henretty, Michael Kohler, Josh Meyer, Reuben Morais, Lindsay Saunders, Francis M Tyers, and Gregor Weber. Common voice: A massively-multilingual speech corpus. arXiv preprint arXiv:1912.06670, 2019.
- [48] Alexis Conneau, Min Ma, Simran Khanuja, Yu Zhang, Vera Axelrod, Siddharth Dalmia, Jason Riesa, Clara Rivera, and Ankur Bapna. Fleurs: Few-shot learning evaluation of universal representations of speech. In 2022 IEEE Spoken Language Technology Workshop (SLT), pages 798–805. IEEE, 2023.
- [49] Ziyang Ma, Mingjie Chen, Hezhao Zhang, Zhisheng Zheng, Wenxi Chen, Xiquan Li, Jiabin Ye, Xie Chen, and Thomas Hain. Emobox: Multilingual multi-corpus speech emotion recognition toolkit and benchmark. In Proc. INTERSPEECH, 2024.
- [50] Yaoxun Xu, Hangting Chen, Jianwei Yu, Qiaochu Huang, Zhiyong Wu, Shixiong Zhang, Guangzhi Li, Yi Luo, and Rongzhi Gu. Secap: Speech emotion captioning with large language model. arXiv preprint arXiv:2312.10381, 2023.
- [51] Neil Zeghidour, Alejandro Luebs, Ahmed Omran, Jan Skoglund, and Marco Tagliasacchi. Soundstream: An end-to-end neural audio codec. IEEE ACM Trans. Audio Speech Lang. Process., 30:495–507, 2022.
- [52] Wei-Ning Hsu, Benjamin Bolte, Yao-Hung Hubert Tsai, Kushal Lakhotia, Ruslan Salakhutdinov, and Abdelrahman Mohamed. Hubert: Self-supervised speech representation learning by masked prediction of hidden units. IEEE/ACM transactions on audio, speech, and language processing, 29:3451–3460, 2021.
- [53] Yu-An Chung, Yu Zhang, Wei Han, Chung-Cheng Chiu, James Qin, Ruoming Pang, and Yonghui Wu. W2v-bert: Combining contrastive learning and masked language modeling for self-supervised speech pre-training. In 2021 IEEE Automatic Speech Recognition and Understanding Workshop (ASRU), pages 244–250. IEEE, 2021.