

CosyVoice: 一种基于监督语义标记的可扩展多语言零样本文本到语音合成器

Zhihao Du, Qian Chen, Shiliang Zhang, Kai Hu, Heng Lu, Yexin Yang
Hangrui Hu, Siqi Zheng, Yue Gu, Ziyang Ma, Zhifu Gao, Zhijie Yan

Speech Lab, Alibaba Group, China

{ neo.dzh, sly.zsl, h.lu } @alibaba-inc.com

Abstract

近年来, 基于大型语言模型 (LLM) 的文本转语音 (TTS) 技术因其高自然度和零样本学习能力而成为主流。在该范式中, 语音信号被离散化为词元序列, LLM 以文本作为提示对这些词元序列进行建模, 并通过基于词元的声码器将其重构为波形。显然, 语音词元在基于 LLM 的 TTS 模型中起着至关重要的作用。目前的语音词元学习方式是无监督的, 缺乏显式的语义信息和与文本的对齐。本文提出了一种基于监督语义的语音表示方法, 该方法通过在编码器中插入矢量量化, 从多语言语音识别模型中导出语义词元。基于这些词元, 我们进一步提出了一种基于编解码器的语音生成合成器 CosyVoice¹, 它由用于文本到词元生成的 LLM 和用于词元到语音合成的条件流匹配模型组成。实验结果表明, 在零样本语音克隆中, 监督语义标记在内容一致性和说话人相似度方面显著优于现有的无监督标记。此外, 我们发现利用大规模数据可以进一步提升合成性能, 这表明 CosyVoice 具有良好的可扩展性。据我们所知, 这是首次尝试将监督语音标记引入 TTS 模型。

1 简介

近年来, 文本转语音 (TTS) 技术取得了显著进步, 从最初的机械音发展到如今几乎可以以假乱真的语音。大型语言模型 (LLM) 是推动这一进步的关键, 它们已被越来越多地应用于文本转语音 (TTS) 系统中, 以生成更自然、更易于理解的语音, 并能够以零样本的方式合成语音。这些基于 LLM 的 TTS 模型通过将语音信号转换为词元序列来工作, LLM 利用文本作为条件来对这些词元序列进行建模。然后, 使用词元声码器从分词后的语音中重建原始波形。

TTS 过程的一个关键方面是语音词元的表示。传统上, 词元是通过无监督学习获得的, 但这可能无法捕捉到明确的语义信息, 也可能

无法与相应的文本很好地匹配。为了弥补这一不足, 我们的工作引入了监督语义词元, 这些词元是通过将矢量量化集成到编码器中, 从多语言语音识别模型 Whisper 中提取出来的。这项创新实现了更精确的语义表示和文本对齐。早期研究表明, 对于语音到文本翻译和自动语音识别 (ASR) 任务, 带有辅助 ASR 损失的量化器在通用语音模型 (USM) 上的性能优于 k-means 聚类, 如 Rubenstein et al. (2023) 所示。此外, Ye et al. (2024) 采用 Gumbel-Softmax 矢量量化来提取离散语音表示, 优先考虑与 ASR 相关的信息, 以用于 ASR 任务。然而, 这些方法对文本到语音 (TTS) 的影响尚不明确。

此外, 利用这些监督式标记, 我们提出了 CosyVoice, 一个可扩展且高效的零样本 TTS 合成器。CosyVoice 由一个逻辑逻辑模型 (LLM) 和一个条件流匹配模型组成, LLM 用于将文本转换为语义标记序列, 而条件流匹配模型用于从这些标记合成语音。与 TorToise TTS (Betker, 2023) 等先前的系统 (后者采用 LLM 结合去噪扩散概率模型 (DDPM) (Ho et al., 2020)) 不同, CosyVoice 采用条件流匹配方法, 该方法已被证明比传统扩散模型 (Le et al., 2024) 更能加速训练和推理。虽然现有方法在 TTS (Le et al., 2024; Guo et al., 2023; Mehta et al., 2023; Guan et al., 2023) 中也采用了流匹配, 但它们通常依赖于音素时长预测, 因此需要使用辅助音素器和强制对齐器。然而, CosyVoice 绕过了这些依赖性, 提供了一条更直接、更高效的文本到语音转换路径。

我们的研究以多种创新方式为语音生成领域做出了贡献:

- 我们率先将监督语音标记集成到 TTS 模型中, 从而增强了零样本语音克隆中的内容一致性和说话人相似度。
- 我们提出了 CosyVoice, 一个可扩展的零样本 TTS 合成系统。该系统结合了用于文本到词元生成的 LLM 模型和用于词元到语音合成的条件流匹配模型, 无需额外的音素器和强制对齐器。
- 为了进一步提升生成语音的质量, 我们将 x

¹模型和代码发布于 <https://github.com/FunAudioLLM/CosyVoice>。演示代码可在 <https://fun-audio-llm.github.io> 找到。

向量 (Snyder et al., 2018) 集成到 LLM 模型中, 将语音建模分解为语义、说话人和韵律三个组成部分。LLM 模型负责语义内容和韵律的建模, 而条件流匹配模型则负责捕捉音色和环境信息。我们利用诸如无分类器引导 (Ho and Salimans, 2022a)、余弦调度器和掩码条件等技术优化了流匹配过程。

我们的实验结果表明, 监督式语义词元优于无监督式词元。此外, CosyVoice 的可扩展性也体现在其在大规模数据上合成性能的提升。因此, 这项工作代表着在开发自然流畅、功能全面的文本转语音 (TTS) 系统方面迈出的重要一步。

如图 1 (b) 所示, 我们的 CosyVoice 由四个组件构成: 文本编码器、语音分词器、大型语言模型和条件流匹配模型。具体来说, 文本编码器用于对齐文本和语音标记的语义空间, 而语音分词器用于提取语义标记, 如图 1 (a) 所示。我们采用大型语言模型来学习完整的文本编码和语音标记序列, 将文本转语音 (TTS) 问题重新表述为以文本作为提示的自回归序列生成问题。然后, 如图 1 (c) 所示, 利用条件流匹配模型, 通过最优路径上的去噪过程, 将语音标记转换为梅尔频谱图。为了获得可感知的信号, 使用 HiFiGAN 声码器 (Kong et al., 2020), 以生成的梅尔频谱图作为输入, 合成波形。

1.1 语音监督语义标记

在 CosyVoice 中, 采用监督式自动语音识别 (ASR) 模型来导出用于语音的监督式语义语音 ($\mathcal{S}^3$) 分词器。该模型是我们专有的 SenseVoice ASR 模型的微调版本。它使用多语言音频数据进行训练, 并具有丰富的音频内容理解能力。与原始 ASR 模型不同, 我们将编码器分为两部分, 并在它们之间插入一个矢量量化层。给定一个梅尔频谱图 X 作为输入, 它经过位置编码 Encoder_1 得到上下文感知表示 H :

$$H = \text{Encoder}_1(\text{PosEnc}(X)) \quad (1)$$

然后, 引入矢量量化器 (VQ) 以获得离散的词元。对于帧 l 的隐藏表示 h_l , 码本 C 中最近的嵌入索引被视为该时间步的语音词元 μ_l :

$$\mu_l = \text{VQ}(h_l, C) = \arg \min_{c_n \in C} \|h_l - c_n\|_2 \quad (2)$$

其中 $\|\cdot\|_2$ 表示 L2 范数。在训练阶段, 码本嵌入通过指数移动平均 (EMA) 进行更新:

$$c_{\mu_l} := \alpha c_{\mu_l} + (1 - \alpha) h_l \quad (3)$$

其中 α 是预定义的衰减系数。语音标记对应的码本嵌入被用作量化的隐藏表示 $\bar{H} = \{c_{\mu_1}, c_{\mu_2}, \dots, c_{\mu_L}\}$, 并传递给剩余的编码器层 Encoder_2 :

$$\tilde{H} = \text{Encoder}_2(\text{PosEnc}(\bar{H})) \quad (4)$$

注意, 在剩余的编码器层之前, 我们添加了一个额外的位置编码来增强时间信息。在 Encoder_2 之后, 紧接着一个基于 Transformer 的 ASR 解码器, 用于预测文本标签的后验概率:

$$P(Y|X) = \text{ASRDecoder}(\tilde{H}, Y^{Z-1}) \quad (5)$$

其中 Y^{Z-1} 表示教师强制训练方案中左移的文本标签。

1.2 用于文本转语音的大型语言模型

在本节中, 我们将 TTS 任务建模为一个基于大型语言模型 (LLM) 的自回归语音标记生成问题。对于 LLM 而言, 序列构建至关重要, 其构建方式如下:

$$[\textcircled{\text{S}}, v, \{\bar{y}_u\}_{u \in [1:U]}, \textcircled{\text{T}}, \{\mu_l\}_{l \in [1:L]}, \textcircled{\text{E}}] \quad (6)$$

$\textcircled{\text{S}}$ 和 $\textcircled{\text{E}}$ 分别表示序列的起始点和结束点。 v 是使用预训练的声纹模型²从语音 X 中提取的说话人嵌入向量。文本编码 $\bar{Y} = \{\bar{y}_u\}_{u \in [1:U]}$ 是通过将文本依次经过字节对编码 (BPE) 标记器和文本编码器得到的:

$$\bar{Y} = \text{TextEncoder}(\text{BPE}(Y)) \quad (7)$$

由于文本和语音标记处于不同的语义层次, 因此使用文本编码器来对齐它们的语义空间, 从而有利于 LLM 建模。在文本编码和语音标记 $\{\mu_l\}_{l \in [1:L]}$ 之间插入起始标识符 $\textcircled{\text{T}}$, 其中语音标记 $\{\mu_l\}_{l \in [1:L]}$ 由监督语义分词器提取, 如 1.1 中所述。在训练阶段, 我们采用教师强制方案, 其中左移序列作为模式输入, 原始序列作为期望输出。请注意, 训练过程中仅考虑语音标记和 $\textcircled{\text{E}}$ 的交叉熵损失:

$$\mathcal{L}_{LM} = -\frac{1}{L+1} \sum_{l=1}^{L+1} \log q(\mu_l) \quad (8)$$

其中 μ_{L+1} 是“序列结束”标记 $\textcircled{\text{E}}$ 。 $q(\mu_l)$ 表示 μ_l 的后验概率, 该概率由 LLM 之后的 softmax 层预测。

²可在以下网址获取: <https://github.com/alibaba-damo-academy/3D-Speaker/tree/main/egs/3dspeaker/sv-cam++>




Figure 1: CosyVoice 模型概述。(a) 展示了 $\mathcal{S}^3$ 分词器，其中虚线模块仅在训练阶段使用。(b) 是 CosyVoice 的示意图，它由文本到词元的语言学习模型 (LLM) 和词元到语音的流匹配模型组成。 $\textcircled{S}$ 、 $\textcircled{E}$ 和 $\textcircled{T}$ 分别表示“序列开始”、“序列结束”和“语音转换”词元。虚线表示推理阶段的自回归解码。(c) 展示了我们的流匹配模型在概率密度路径上，以说话人嵌入 $\mathbf{v}$ 、语义标记 μ 、掩码语音特征 $\tilde{X}$ 和时间步 t 的中间状态 X_t 为条件的放大视图。

CosyVoice 采用最优传输条件流匹配模型 (OT-CFM) 来学习梅尔频谱图的分布，并以生成的语音标记作为条件从中生成样本。与扩散概率模型 (DPM) 相比，OT-CFM 具有更简单的梯度、更容易的训练和更快的生成速度，因此性能更佳。在连续时间归一化流 (CNF) 中，从先验分布到梅尔频谱图的数据分布构建概率密度路径。概率密度路径由时变向量场 $\nu_t(X) : [0, 1] \times \mathbb{R}^{L \times D} \rightarrow \mathbb{R}^{L \times D}$ 定义，它通过以下常微分方程 (ODE) 生成流 ϕ_t ：

$$\begin{aligned} \frac{d}{dt} \phi_t(X) &= \nu_t(\phi_t(X), t) \\ \phi_0(X) &\sim p_0(X) = \mathcal{N}(X; 0, I) \\ \phi_1(X) &\sim p_1(X) \end{aligned} \quad (9)$$

其中 $t \in [0, 1]$ 。通过求解初值问题方程 (9)，我们可以用 $p_1(X)$ 近似语音分布 $q(X)$ 并从中进行采样。为了学习向量场 $\nu_t(X)$ ，我们定义了最优传输 (OT) 流，并通过最小化以下损失来强制神经网络与之匹配：

$$\begin{aligned} \mathcal{L}_{OT-CFM} &= \mathbb{E}_{t, p_0(X_0), q(X_1)} |\omega_t(\phi_t^{OT}(X_0, X_1)|X_1) - \nu_t(\phi_t^{OT}(X_0, X_1)|\theta)| \end{aligned} \quad (10)$$

其中

$$\begin{aligned} \phi_t^{OT}(X_0, X_1) &= (1 - (1 - \sigma)t)X_0 + tX_1 \\ \omega_t(\phi_t^{OT}(X_0, X_1)|X_1) &= X_1 - (1 - \sigma)X_0 \end{aligned} \quad (11)$$

说话人嵌入 $\mathbf{v}$ 、语音标记 $\{\mu_l\}_{1:L}$ 和掩码梅尔频谱图 $\tilde{X}_1$ 也被输入到神经网络中，以使用可学习参数 θ 来匹配向量场：

$$\begin{aligned} \nu_t(\phi_t^{OT}(X_0, X_1)|\theta) &= \text{NN}_\theta \left(\phi_t^{OT}(X_0, X_1), t; \mathbf{v}, \{\mu_l\}_{1:L}, \tilde{X}_1 \right) \end{aligned} \quad (12)$$

$\tilde{X}_1$ 是 X_1 的掩码版本，通过将随机起点到终点的连续帧设置为零来实现。考虑到初始生成过程比后续过程更困难，我们引入了一个余弦调度器来处理时间步 t ：

$$t := 1 - \cos \left(\frac{1}{2} t \pi \right) \quad (13)$$

在调度流下，初始阶段有更多的生成步骤。

无分类器引导 (CFG) 已被证明可以提高扩散概率模型 (Ho and Salimans, 2022b; Nichol and Dhariwal, 2021; Le et al., 2024) 的生成质量。因此，我们提出将 CFG 应用于条件流匹配模型。在训练阶段，我们以固定的概率 0.2 随机丢弃条件 $\Psi = \{\mathbf{v}, \{\mu_l\}_{1:L}, \tilde{X}_1\}$ 。这样，我们就可以学习条件流和无条件流。在生成过程中，向量场修改如下：

$$\begin{aligned} \tilde{\nu}_t(\phi_t^{OT}(X_0, X_1)|\theta; \Psi) &= (1 + \beta) \cdot \nu_t(\phi_t^{OT}(X_0, X_1)|\theta; \Psi) \\ &\quad - \beta \cdot \nu_t(\phi_t^{OT}(X_0, X_1)|\theta) \end{aligned} \quad (14)$$

其中 β 是 0.7 的引导强度。




Figure 2: 用于 (a) 零样本上下文学习和 (b) 跨语言语音克隆的序列构建。LID 表示语言标识符。

1.2.1 零样本上下文学习

CosyVoice 模型具备零样本上下文学习能力，仅需一个简短的参考语音样本即可复现任意语音。该过程需要精心构建标记语言模型 (LM) 的输入序列，如图 2 所示。对于同一种语言的提示语音和输入文本，我们将其合并为统一的输入，并将提示语音标记视为预先生成的。利用该输入序列，自回归 LM 会迭代预测后续标记，直至遇到“序列结束”标记 $\textcircled{E}$ 。然而，当提示语音和输入文本在语言上存在差异时，我们会省略与提示相关的文本和标记，以防止原始语言的韵律特征影响目标语言。需要注意的是，与提示语音内容对应的提示文本可以通过人工标注或自动语音识别 (ASR) 模型（例如 SenseVoice）进行转录。与提示文本类似，提示词元也是使用 $\mathcal{S}^3$ 分词器从提示语音中提取出来的。

生成语音词元后，它们会被附加到提示词元之后，形成流匹配模型的复合条件。此外，还会结合提示语音的说话人嵌入和梅尔频谱图，以进一步增强音色和环境一致性。

1.3 基于指令的富文本生成

为了进一步增强 CosyVoice 的控制能力，我们尝试集成额外的指令微调 (Ji et al., 2023)。CosyVoice-instruct 扩展了 CosyVoice-base，增强了指令跟随功能。具体来说，它支持对说话人身份（即说话人的特征）、说话风格（包括情感、性别、语速和音调）以及细粒度副语言特征等各个方面的控制。这些特征包括插入笑声、呼吸声、边笑边说以及强调某些词语。

我们使用此训练数据对 CosyVoice-base 进行了微调，但未将说话人嵌入纳入自回归语言模型。表 1 展示了说话人身份、说话风格和细粒度副语言特征的一些示例。

2 数据集

2.1 小规模单语言数据集

我们在 LibriTTS (Zen et al., 2019) 语料库上进行了实验，该语料库包含来自 2456 位英语说话者的 585 小时语音。我们遵循官方数据划

分，将“train-clean-100”、“train-clean-360”和“train-other-500”合并用于训练，“dev-clean”用于模型选择。“test-clean”用于构建评估集，具体方法参见 (Du et al., 2024)。

2.2 大规模多语言数据集

为了训练 CosyVoice 模型，我们收集了一个包含多种语言的庞大数据集。在整个数据采集过程中，我们使用自主研发的语音检测、信噪比 (SNR) 估计、说话人分割和分离工具。随后，我们使用 SenseVoice-Large 和 Paraformer 生成伪文本标签。这些标签会借助力对齐 (FA) 模型进行优化，从而去除低质量数据并提高标点符号的准确性。表 2 详细列出了不同语言训练数据的持续时间。表 3 则展示了不同类型指令的训练数据持续时间。

3 实验设置

3.1 监督式语义语音分词器

对于小规模单语言数据集，我们采用 ESPNet Conformer ASR 模型作为骨干网络，并在前六个编码器层之后插入矢量量化器。该数据集包含一个 4096 个码本。前六个编码器层和矢量量化器用作语音分词器。对于文本分词器，我们使用词汇量为 4000 的训练文本训练了一个词句片段模型。我们从头开始，在 Librispeech (Panayotov et al., 2015) 语料库上训练量化增强型 ASR 模型 50 个 epoch。

对于大规模多语言数据集，我们采用 SenseVoice-Large 丰富的语音识别模型 (TongyiSpeech, 2024) 作为骨干网络。与小规模数据集类似，我们仍然在前六个编码器层之后插入一个矢量量化器，使用一个包含 4096 个码位的码本。更多超参数的选择，例如量化器插入层和码位数量，留待后续研究。与单语言实验不同，我们使用预训练的检查点来初始化 SenseVoice-Large 模型，而不是从头开始训练。插入量化器后，我们在八块 A800 GPU 上进行了 21 万次训练，进一步微调所有参数。

3.2 CosyVoice 模型设置

我们在单语言和多语言实验中分别训练了小型和常规尺寸的模型。模型架构设置的详细信息见表 4。微型模型使用 LibriTTS 训练集，在 4 个 V100-32M GPU 上训练 50 个 epoch；多语言模型使用我们内部的数据集，在 64 个 V100-32M GPU 上训练 800,000 步。微型模型和普通模型的学习率分别为 10^{-3} 和 10^{-4} 。预热步数设置为 10,000。

Speaker Identity
1. Selene 'Moonshade', is a mysterious , elegant dancer with a connection to the night. Her movements are both mesmerizing and deadly .<endofprompt>Hope is a good thing.
2. Theo 'Crimson', is a fiery , passionate rebel leader. Fights with fervor for justice, but struggles with impulsiveness .<endofprompt>You don't know about real loss.
Speaking Style
1. A happy girl with high tone and quick speech .<endofprompt>The sun is shining brightly today.
2. A sad woman with normal tone and slow speaking speed .<endofprompt>I failed my important exam.
Fine-grained Paralinguistics
1. Well that's kind of scary [laughter] .
2. I don't think I over eat yeah [breath] and um I do exercise regularly.
3. Well that pretty much covers <laughter>the subject</laughter> well thanks for calling me.
4. The team's unity and resilience helped them win the championship.

Table 1: 说话人身份、说话风格和细粒度副语言学示例。

Language	Duration (hr)
ZH	130,000
EN	30,000
Yue	5,000
JP	4,600
KO	2,200

Table 2: 大规模实验中, CosyVoice 跨语言的训练数据 (耗时数小时)。

Type	Duration (hr)
Speaker Identity	101
Speaking Style	407
Fine-grained Paralinguistics	48

Table 3: 按类型划分的指令训练数据持续时间统计。

4 实验结果

4.1 使用 S^3 分词器进行评估

在表 5 中, 我们展示了矢量量化如何影响 LibriTTS 测试集上的识别性能。从表中可以看出, 在 ASR 编码器中插入矢量量化器对识别性能的影响很小。因此, 插入矢量量化器的 Conformer ASR 模型在 “test-clean” 和 “test-other” 数据集上分别取得了 3.18 % 和 7.56 % 的相近词错误率 (WER)。这表明, 以监督方式训练的分词器能够保持足够的语义信息并与文本对齐。

为了评估多语言 S^3 分词器保留语义信息的能力, 我们将量化增强的 SenseVoice-L 与其原始版本以及 Whisper-Large V3 模型进行了识别性能比较。我们使用 Common Voice zh-CN 和 en 基准数据集对这些模型进行了评估, 结果详见表 6。从表中可以看出, 我们的 S^3 分词器在中文和英文测试集上均表现出稳健的识别性能。值得注意的是, 在 common_voice_zh-CN 数

Settings	Tiny	Normal
Text Encoder		
Layers	6	6
Attention Dim.	512	1,024
Attention Heads	8	16
Linear Units	2,048	4,096
Language Model		
Layers	12	14
Attention Dim.	512	1,024
Attention Heads	8	16
Linear Units	2,048	4,096

Table 4: 微型和普通 CosyVoice 模型架构设置详情。

Model	dev_clean	test_clean	test_other
Conformer	2.62	2.89	6.57
Conformer-VQ	3.13	3.18	7.56

Table 5: 插入矢量量化对语音识别词错误率 (%) 的影响。

据集上, S^3 分词器的性能优于 Whisper-Large V3 模型 (TongyiSpeech, 2024), 错误率相对降低了 4.14 %。这表明 S^3 分词器与语义内容之间存在显著的相关性。值得注意的是, S^3 分词器中只有一个码本, 其词典大小为 4,096 个条目。

4.2 与基线系统的比较

我们将提出的 CosyVoice 模型与其他 TTS 系统在内容一致性和说话人相似度方面进行比较。对于内容一致性, 我们采用 ASR 模型来识别生成的语音。我们报告了词错误率 (WER) 以及插入错误、删除错误和替换错误的数量。对于说话人相似度, 我们采用 ERes2Net 模型 (Chen et al., 2023) 来提取提示语音和生成语音的说话人嵌入, 并将它们的原始余弦相似度作为说话人相似度。实验结果如表 7 所示。

Test set	Whisper-L-V3		SenseVoice-L		S^3 tokens	
	w/o lid	w/ lid	w/o lid	w/ lid	w/o lid	w/ lid
zh-CN	12.82	12.55	8.76	8.68	12.24	12.06
en	13.55	9.39	9.79	9.77	15.43	15.38

Table 6: 在 S^3 上评估词元保留语义信息的能力。我们使用 Common Voice 基准测试中中文和英文的词错误率和字符错误率。

与其他文本转语音 (TTS) 模型相比, 即使使用相同的文本和语音分词器, 我们提出的 CosyVoice 框架也能实现相当的内容一致性和更高的说话人相似度。比较实验 Exp-1、Exp-2 和 Exp-3, 我们可以看出, 文本和语音分词器对于内容一致性至关重要, 而对说话人相似度的影响可以忽略不计。在实验 Exp-4 中, 我们将单语言文本和语音分词器替换为多语言分词器。仅使用 LibriTTS 语料库训练模型会降低内容一致性和说话人相似度。通过引入内部大规模数据集, 性能显著提升, 达到了与人类语音媲美的质量。

我们通过考察内容一致性和说话人相似度来评估 CosyVoice 的语音合成质量。我们分别使用 LibriTTS (Zen et al., 2019) 的 “test-clean” 子集和 AISHELL-3 (Shi et al., 2021) 的测试集构建英语和汉语的评估集。对于这些评估集中的每篇文本, 我们随机选择一个提示语音。我们使用 Whisper-Large V3 (Radford et al., 2023) (英语) 和 Paraformer (Gao et al., 2022) (汉语) 评估内容一致性。说话人相似度通过计算生成语音和提示语音的说话人嵌入之间的余弦相似度来量化, 说话人嵌入由 ERes2Net (Chen et al., 2023) 提取。

与其他自回归语言模型类似, 我们对词元语言模型 (TOM) 采用了随机采样解码策略, 并使用五个不同的随机种子值 (0、7、42、123 和 1337) 评估了合成过程。我们将评估指标取平均值, 以确定均值和标准差。此外, 我们还进行了 ASR 重排序, 以展示离线模式下潜在的性能提升。

表 8 和 9 分别展示了英语和中文的测试结果。在英语数据集上, CosyVoice 达到了人类水平的性能, 内容识别率相近, 说话人相似度更高。ASR 重排序显著提高了内容一致性, 使词错误率 (WER) 降低至 1.51 %。CosyVoice 在 WER 和插入/删除错误数量方面均优于 ChatTTS, 表明其内容一致性更佳。由于 ChatTTS 不具备语音克隆功能, 因此我们没有评估其说话人相似度。

就中文结果而言, CosyVoice 生成的语音与原始语音相比, 在 CER 以及插入和删除错误方面都达到了相当的水平。就 CER 而言,

ChatTTS 在中文生成方面似乎比英语更胜一筹。尽管 ChatTTS 和 CosyVoice 的 CER 相近, 但 ChatTTS 产生的插入和删除错误更多, 这是由于说话人泄露问题造成的, 即意外地生成了其他说话人的语气词。相反, CosyVoice 不存在这个问题, 插入和删除错误要少得多。经过 ASR 重排序后, CosyVoice 的 CER 达到了惊人的低值 1.84 %。与英语结果类似, CosyVoice 的说话人相似度也高于原始语音, 展现了其高效的语音克隆能力。

为了验证情感可控性, 我们使用了公开的语音情感识别模型 emo2vec。我们针对六种情感 (快乐、愤怒、悲伤、惊讶、恐惧和厌恶) 分别生成并评估了 100 条英文语音。合成文本的内容旨在与目标情感相匹配。然后, 我们测量了合成语音对每种情感的预测准确率。

表 10 展示了 CosyVoice-base 和 CosyVoice-instruct 在情感控制准确率方面的比较。对于 CosyVoice-instruct, 输入包含内容文本以及语音风格指令 (例如, “Happy. < endofprompt > Content Text”)。相比之下, CosyVoice-base 仅接收内容文本作为输入。结果表明, 带有情感指令的 CosyVoice-instruct 相较于 CosyVoice-base 和不带情感指令的 CosyVoice-instruct 均有显著提升。

4.3 CosyVoice 作为数据生成器

CosyVoice 的一个直接应用是作为数据生成器, 用于扩充其他任务 (例如自动语音识别 (ASR) 和语音到语音翻译 (S2ST)) 的训练数据。以 ASR 任务为例, 我们在 Librispeech 语料库上进行了一项实验, 以评估 CosyVoice 生成高质量数据的能力。实验结果如表 11 所示, 其中 “Librispeech” 表示原始的 960 小时数据。“Syn on LS text” 和 “Syn on LS text” 分别表示使用 Librispeech 和 MLS 训练集中的文本生成的数据。从表中可以看出, 仅使用合成数据进行训练, ASR 模型即可达到与原始 Librispeech 训练集相当的结果。将两者结合起来后, 识别准确率显著提高。一个有趣的发现是, 将 MLS 文本上的合成数据纳入训练可以显著提高识别性能。这可能表明, 对于 ASR 任务而言, 文本多样性比语音时长本身更为关键。这种改进可归因于 CosyVoice 合成样本引入的多样化语言内容。我们的评估结果强调了 CosyVoice 生成的样本的高质量。

本文介绍了一种可扩展的多语言语音生成模型 CosyVoice, 它支持零样本上下文学习、跨语言语音克隆、指令生成以及对情感和副语言特征的细粒度控制。实验结果表明, CosyVoice 的系统架构对说话人相似度至关重要, 而文本

Model	Text token	Speech Token	WER (%)	# INS+DEL	# SUB	SS
Original	-	-	3.01	66	200	69.67
VALL-E (Wang et al., 2023)	Phone	Encodec	18.70	342	1312	53.19
UniAudio (Yang et al., 2023)	Phone	Encodec	8.74	254	519	47.56
SpearTTS (Kharitonov et al., 2023)	Phone	Hubert	6.14	133	410	51.71
Exp-1-LibriTTS	Phone	Hubert	7.41	325	409	67.85
Exp-2-LibriTTS	Phone	S^3_{en}	5.05	122	325	67.85
Exp-3-LibriTTS	BPE _{en}	S^3_{en}	3.93	108	239	67.85
Exp-4-LibriTTS	BPE	S^3	4.76	134	287	65.94
Exp-4-Large-scale	BPE	S^3	3.17	96	184	69.49

Table 7: 在 LibriTTS 测试集上，我们以内容一致性和说话人相似度 (SS) 为指标，将本模型与其他 TTS 模型进行了比较。为了快速评估，我们采用了非自回归 ASR 模型 Paraformer-en。

Model	WER (%)	# Ins. & Del.	SS
Original	2.66	92	69.67
ChatTTS	8.32	441	-
CosyVoice	2.89±0.18	88.60±3.88	74.30±0.15
+ 5× re-ranking	1.51	47	74.30

Table 8: 在 LibriTTS 测试集上，我们比较了原始语音和 CosyVoice 生成的语音的词错误率 (WER) 和说话人相似度 (SS)。“±”表示每个评估指标的均值和标准差。采用 Whisper-Large V3 作为自动语音识别 (ASR) 模型。

Model	CER (%)	# Ins. & Del.	SS
Original	2.52	25	74.15
ChatTTS	3.87	111	-
CosyVoice	3.82±0.24	24.4±2.24	81.58±0.16
+ 5× re-ranking	1.84	11	81.58

Table 9: 在 AISHELL-3 测试集上，比较原始语音和 CosyVoice 生成的语音的字符错误率 (CER) 和说话人相似度 (SS)。采用 Paraformer-zh 作为 ASR 模型。

和语音分词器对内容一致性影响很大。此外，我们发现增加模型规模和数据量可以显著提高性能。因此，CosyVoice 能够达到与人类语音媲美的生成质量。

References

James Betker. 2023. [Better speech synthesis through scaling](#). *CoRR*, abs/2305.07243.

Yafeng Chen, Siqi Zheng, Hui Wang, Luyao Cheng, Qian Chen, and Jiajun Qi. 2023. An enhanced res2net with local and global feature fusion for speaker verification. In *Interspeech*. ISCA.

Chenpeng Du, Yiwei Guo, Feiyu Shen, Zhijun Liu, Zheng Liang, Xie Chen, Shuai Wang, Hui Zhang, and Kai Yu. 2024. Unicats: A unified context-aware text-to-speech framework with contextual vq-

diffusion and vocoding. In *AAAI*, pages 17924–17932. AAAI Press.

Zhifu Gao, Shiliang Zhang, Ian McLoughlin, and Zhi-jie Yan. 2022. Paraformer: Fast and accurate parallel transformer for non-autoregressive end-to-end speech recognition. In *Interspeech*, pages 2063–2067. ISCA.

Wenhao Guan, Qi Su, Haodong Zhou, Shiyu Miao, Xingjia Xie, Lin Li, and Qingyang Hong. 2023. [Reflow-tts: A rectified flow model for high-fidelity text-to-speech](#). *CoRR*, abs/2309.17056.

Yiwei Guo, Chenpeng Du, Ziyang Ma, Xie Chen, and Kai Yu. 2023. [Voiceflow: Efficient text-to-speech with rectified flow matching](#). *CoRR*, abs/2309.05027.

Jonathan Ho, Ajay Jain, and Pieter Abbeel. 2020. [De-noising diffusion probabilistic models](#). In *Advances in Neural Information Processing Systems 33: Annual Conference on Neural Information Processing Systems 2020, NeurIPS 2020, December 6-12, 2020, virtual*.

Jonathan Ho and Tim Salimans. 2022a. [Classifier-free diffusion guidance](#). *CoRR*, abs/2207.12598.

Jonathan Ho and Tim Salimans. 2022b. Classifier-free diffusion guidance. *arXiv preprint arXiv:2207.12598*.

Shengpeng Ji, Jialong Zuo, Minghui Fang, Ziyue Jiang, Feiyang Chen, Xinyu Duan, Baoxing Huai, and Zhou Zhao. 2023. Textrolspeech: A text style control speech corpus with codec language text-to-speech models. *CoRR*, abs/2308.14430.

Eugene Kharitonov, Damien Vincent, Zalán Borsos, Raphaël Marinier, Sertan Girgin, Olivier Pietquin, Matt Sharifi, Marco Tagliasacchi, and Neil Zeghidour. 2023. Speak, read and prompt: High-fidelity text-to-speech with minimal supervision. *Trans. Assoc. Comput. Linguistics*, 11:1703–1718.

Jungil Kong, Jaehyeon Kim, and Jaekyoung Bae. 2020. [Hifi-gan: Generative adversarial networks for efficient and high fidelity speech synthesis](#). In *Advances*

Model	Happy	Sad	Angry	Surprised	Fearful	Disgusted
CosyVoice-base	1.00±0.00	0.45±0.05	0.59±0.03	0.26±0.02	0.88±0.01	0.46±0.06
CosyVoice-instruct	1.00±0.00	0.98±0.02	0.83±0.04	0.64±0.03	0.87±0.03	0.93±0.02
w/o instruction	0.98±0.01	0.77±0.04	0.49±0.12	0.28±0.06	0.83±0.04	0.45±0.16

Table 10: 比较 CosyVoice-base-300M 和 CosyVoice-instruct-300M 的情感控制准确率。“±”表示每个评估指标的均值和标准差。

Training Data	dev_clean	dev_other	test_clean	test_other
Librispeech	2.77	5.84	2.79	5.97
Syn on LS text	2.79	6.37	3.00	6.59
Librispeech + Syn on LS text	2.44	5.52	2.56	5.68
Librispeech + Syn on LS text ×2	2.51	5.23	2.68	5.26
Librispeech + Syn on LS, MLS text	1.93	4.43	2.04	4.53

Table 11: 将 CosyVoice 视为数据生成器，评估其生成质量。采用人类发音测试集上的词错误率（%）作为评估指标。

- in *Neural Information Processing Systems 33: Annual Conference on Neural Information Processing Systems 2020, NeurIPS 2020, December 6-12, 2020, virtual*.
- Matthew Le, Apoorv Vyas, Bowen Shi, Brian Karter, Leda Sari, Rashel Moritz, Mary Williamson, Vimal Manohar, Yossi Adi, Jay Mahadeokar, et al. 2024. Voicebox: Text-guided multilingual universal speech generation at scale. *Advances in neural information processing systems*, 36.
- Shivam Mehta, Ruibo Tu, Jonas Beskow, Éva Székely, and Gustav Eje Henter. 2023. Matcha-tts: A fast TTS architecture with conditional flow matching. *CoRR*, abs/2309.03199.
- Alexander Quinn Nichol and Prafulla Dhariwal. 2021. Improved denoising diffusion probabilistic models. In *International Conference on Machine Learning*, pages 8162–8171. PMLR.
- Vassil Panayotov, Guoguo Chen, Daniel Povey, and Sanjeev Khudanpur. 2015. Librispeech: an asr corpus based on public domain audio books. In *2015 IEEE international conference on acoustics, speech and signal processing (ICASSP)*, pages 5206–5210. IEEE.
- Alec Radford, Jong Wook Kim, Tao Xu, Greg Brockman, Christine McLeavey, and Ilya Sutskever. 2023. Robust speech recognition via large-scale weak supervision. In *International Conference on Machine Learning, ICML 2023, 23-29 July 2023, Honolulu, Hawaii, USA*, volume 202 of *Proceedings of Machine Learning Research*, pages 28492–28518. PMLR.
- Paul K. Rubenstein, Chulayuth Asawaroengchai, Duc Dung Nguyen, Ankur Bapna, Zalán Borsos, Félix de Chaumont Quitry, Peter Chen, Dalia El Badawy, Wei Han, Eugene Kharitonov, Hannah Muckenhirn, Dirk Padfield, James Qin, Danny Rozenberg, Tara N. Sainath, Johan Schalkwyk, Matthew Sharifi, Michelle Tadmor Ramanovich, Marco Tagliasacchi, Alexandru Tudor, Mihajlo Velimirovic, Damien Vincent, Jiahui Yu, Yongqiang Wang, Vicky Zayats, Neil Zeghidour, Yu Zhang, Zhishuai Zhang, Lukas Zilka, and Christian Havnø Frank. 2023. [Audiopalm: A large language model that can speak and listen](#). *CoRR*, abs/2306.12925.
- Yao Shi, Hui Bu, Xin Xu, Shaoji Zhang, and Ming Li. 2021. AISHELL-3: A multi-speaker mandarin TTS corpus. In *Interspeech*, pages 2756–2760. ISCA.
- David Snyder, Daniel Garcia-Romero, Gregory Sell, Daniel Povey, and Sanjeev Khudanpur. 2018. [X-vectors: Robust DNN embeddings for speaker recognition](#). In *2018 IEEE International Conference on Acoustics, Speech and Signal Processing, ICASSP 2018, Calgary, AB, Canada, April 15-20, 2018*, pages 5329–5333. IEEE.
- Team TongyiSpeech. 2024. Funaudio11m: Voice understanding and generation foundation models for natural interaction between humans and llms.
- Chengyi Wang, Sanyuan Chen, Yu Wu, Ziqiang Zhang, Long Zhou, Shujie Liu, Zhuo Chen, Yanqing Liu, Huaming Wang, Jinyu Li, Lei He, Sheng Zhao, and Furu Wei. 2023. [Neural codec language models are zero-shot text to speech synthesizers](#). *CoRR*, abs/2301.02111.
- Dongchao Yang, Jinchuan Tian, Xu Tan, Rongjie Huang, Songxiang Liu, Xuankai Chang, Jiatong Shi, Sheng Zhao, Jiang Bian, Xixin Wu, Zhou Zhao, Shinji Watanabe, and Helen Meng. 2023. Uniaudio: An audio foundation model toward universal audio generation. *CoRR*, abs/2310.00704.
- Lingxuan Ye, Changfeng Gao, Gaofeng Cheng, Liping Luo, and Qingwei Zhao. 2024. [ASQ: an](#)

ultra-low bit rate asr-oriented speech quantization method. *IEEE Signal Process. Lett.*, 31:221–225.

Heiga Zen, Viet Dang, Rob Clark, and et al. 2019. Lib-ritts: A corpus derived from librispeech for text-to-speech. *arXiv:1904.02882*.